2026학년도
연구학교 운영 보고서

2022 개정 교육과정 실현을 위한 ‘교사-AI 협업’ 미래형 학생평가 모델 연구

영역 : 학생평가

기간 : 2026. 3. 1. ~ 2027. 2. 28.(1년간)

울산광역시교육청 지정 정책연구학교
울산광역시 웅촌중학교

차 례

Ⅰ. 연구의 개요 ····· 1
1. 연구의 필요성 ····· 1
2. 연구의 목적 ····· 2
3. 연구의 범위 및 제한점 ····· 3
4. 연구 용어의 정의 ····· 3

Ⅱ. 이론적 배경 ····· 5
1. 관련 이론 ····· 5
2. 선행 연구 분석 및 본 연구의 차별성 ····· 6

Ⅲ. 실태 분석 및 연구과제 설정 ····· 8
1. 학교 현황(SWOT 분석) ····· 8
2. 실태 분석 및 시사점 ····· 8
3. 연구과제 설정 ····· 9

Ⅳ. 운영의 설계 ····· 11
1. 연구 추진 일정 ····· 11
2. 연구 운영 조직 ····· 12

Ⅴ. 연구과제 실행 결과 ····· 14
1. 과제 1 ····· 14
2. 과제 2 ····· 19
3. 과제 3 ····· 29
4. 종합 ····· 36

Ⅵ. 연구의 검증 및 일반화 결과 ····· 39
1. 연구 검증 결과 ····· 39
2. 일반화 결과 ····· 44

Ⅶ. 연구 결과 및 제언 ····· 47
1. 연구 결과 ····· 47
2. 연구의 한계 ····· 48
3. 제언 ····· 49

Ⅷ. 참고문헌 ····· 51

부록 ····· 52

표 목 차

【표 1】연구의 범위 ····· 3
【표 2-1】용어 정의 ····· 3
【표 2-2】용어 정의(추가) ····· 4
【표 3】서·논술형 채점 방식의 세 가지 접근 ····· 5
【표 4】선행 연구 분석 ····· 6
【표 5】학교현황(SWOT 분석) ····· 8
【표 6】실태 분석 ····· 8
【표 7】실태 분석에서 확인된 요구와 대응 전략 ····· 9
【표 8】연구과제 실행 조직도 ····· 10
【표 9】연구 추진 일정 ····· 11
【표 10】연구 운영 조직 ····· 12
【표 11】협의회 운영 결과 ····· 12
【표 12】세부 과제 1-가 요약 ····· 14
【표 13】평가운영 방식 개선 ····· 15
【표 14】세부 과제 1-나 요약 ····· 16
【표 15】세부 과제 1-다 요약 ····· 17
【표 16】연수 운영 결과 ····· 18
【표 17】세부 과제 1-라 요약 ····· 18
【표 18】이음-평가 모델 목표 ····· 19
【표 19】이음-평가 모델 로드맵 ····· 19
【표 20】세부 과제 2-가 요약 ····· 19
【표 21】교실-삶 이음 서·논술형 평가 문항 개발 사례 ····· 20
【표 22】세부 과제 2-나 요약 ····· 21
【표 23】역사과 이음형 표준 루브릭 ····· 22
【표 24】역사과 이음형 표준 루브릭(통합형) ····· 23
【표 25】세부 과제 2-다 요약 ····· 25
【표 26】단계형 비계질문 사례 ····· 27
【표 27】세부 과제 2-라 요약 ····· 29
【표 28】AI 서·논술형 평가 채점 시스템 초기 계획과 실제 운영 방식 비교 ····· 31
【표 29】세부 과제 3-가 요약 ····· 31
【표 30】세부 과제 3-나 요약 ····· 32
【표 31】교과별 교사-AI 비교 채점 결과 ····· 34
【표 32】세부 과제 3-다 요약 ····· 35
【표 33】1차 자체 검증 결과 ····· 39
【표 34】학생 만족도 조사 결과 ····· 41
【표 35】교사 만족도 조사 결과 ····· 42
【표 36】연구학교 성과 공유 일정 ····· 44
【표 37】자료집 ····· 45

Ⅰ 연구의 개요

1 연구의 필요성

가. 2022 개정 교육과정 도입과 미래형 평가 체제 구축의 필요성

2022 개정 교육과정은 지식의 단순 암기를 확인하는 선다형 평가에서 벗어나 학생의 깊이 있는 학습과 고등 사고력을 지원하는 평가로의 전환을 요구하며, 이를 위해서는 선다형 평가를 지양하고 학생의 사고 과정을 측정할 수 있는 서·논술형 평가의 확대가 필수적인 전제조건이 되었다.

나. 울산형 혁신학교(서로나눔학교) 운영의 심화

본교는 2022학년도부터 2025학년도까지 4년간 울산형 혁신학교인 '서로나눔학교'를 운영하며 학생 주도성과 민주적 학교문화 구축에서 의미 있는 성과를 축적하였고, 이를 토대로 2026학년도에 '서로나눔학교(자율학교)'로 재지정됨과 동시에 지난 4년간의 성찰을 담아 '생각과 행동, 마음과 미래'를 잇는다는 취지의 새로운 교육과정 모델 '이음 교육과정'을 수립하였다. 2026학년도부터 본격 적용되는 이음 교육과정은 교실 속 배움과 학생의 실제 삶을 유기적으로 연결하는 것을 목표로 하며, 이 철학을 온전히 구현하기 위해서는 그에 상응하는 미래형 학생평가 체제가 반드시 뒷받침되어야 한다는 문제의식이 본 연구의 직접적인 출발점이 되었다.

다. 서·논술형 평가 확대에 따른 학교 현장의 제한점

서·논술형 평가의 확대는 현장에서 두 가지 현실적인 장벽에 부딪힌다. 하나는 채점과 피드백에 소요되는 교사의 시간과 에너지 부담이 급격히 커진다는 점이고, 다른 하나는 채점 과정에 교사의 주관이 개입될 여지가 커지면서 평가의 공정성에 대한 학생·학부모의 신뢰 확보가 어려워진다는 점이다.

라. AI기술의 도입과 '교사-AI 협업' 모델의 필요성

이 장벽을 극복할 대안으로 AI 기반 서·논술형 평가 채점 시스템이 부상하였다. AI는 교사의 기계적 채점 업무 부담을 경감시키고 일관된 루브릭 적용으로 채점의 객관성을 담보할 잠재력을 지니지만, 학생의 창의성·논리적 독창성·윤리적 가치판단과 같이 AI가 판단하기 어려운 영역은 반드시 교사의 전문적 평가가 필요하다.

이에 본 연구는 AI를 교사의 '대체자'가 아닌 '조력자'로 규정하는 '교사-AI 협업' 평가 모델을 구축하고, 이를 운영 기간 동안 집중적으로 적용·검증하여 현장 적합성을 높이고자 하였다.

마. 소규모 학교, 미래형 평가의 '최적의 테스트베드(Testbed)'

소규모 학교는 통상 대규모 정량적 데이터 수집에는 불리하다고 여겨지지만, 다양한 평가 모델을 신속히 개발하고 심층적으로 적용·검증하는 데는 교사 1인당 학생 수가 적다는 점이 오히려 유리하게 작용할 수 있다. 본 연구는 이 점에 착안하여, 소규모 학교라는 연구 여건을 미래형 평가 모델의 집중 개발·검증에 활용하는 것을 연구 설계의 핵심 전제로 삼았다.

이상의 문제의식에 따라, 본 연구는 2026학년도 새롭게 출발하는 '이음 교육과정'을 성공적으로 안착시키고, 소규모 학교라는 연구 여건을 최대한 활용하여 '교사-AI 협업' 평가 모델을 1년간 집중적으로 운영·검증하며, 그 성과를 타 학교가 활용할 수 있는 실증적 자료로 일반화하는 데 그 필요성과 시급성을 두었다.

본교와 같이 교과별 담당 교사가 1명인 소규모 학교에서는 한 교사가 여러 학년의 정기시험과 수행평가를 동시에 설계·출제·채점해야 하는 구조적 부담이 상존한다. 이 부담은 자칫 서·논술형 평가 확대를 주저하게 만드는 요인이 될 수 있으나, 역으로 교사 1인당 학생 수가 적어 평가 결과를 세밀하게 관찰하고 축적할 수 있다는 강점으로 전환될 여지도 크다.

본 연구는 이 소규모 학교의 이중적 특성(구조적 부담과 질적 연구의 이점)을 있는 그대로 인정하고, 부담을 줄이는 기술적 장치(AI 협업)와 강점을 살리는 운영 방식(정기시험 축소·집중 협의 체제)을 함께 설계함으로써 연구의 실현 가능성을 높이고자 하였다.

2 연구의 목적

본 연구는 본교의 새로운 교육과정인 '이음 교육과정'과 소규모 학교의 강점을 기반으로 2022 개정 교육과정의 비전을 실현할 수 있는 미래형 학생평가 모델을 개발하고, AI 기반 '교사-AI 협업' 평가 체제를 연구학교 운영 기간 동안 집중 적용·검증함으로써 교사의 평가 부담을 경감하고 학생의 지속적인 성장을 지원하는 일반화 방안을 마련하는 데 목적을 두고 다음과 같은 세부 목적을 설정하였다.

가. 이음 교육과정의 철학을 기반으로 교육과정-수업-평가-피드백이 유기적으로 연계되는 '이음-평가 모델'을 구축한다.

나. 2022 개정 교육과정의 핵심 역량과 삶의 맥락을 반영한 '교실-삶 이음 서·논술형 문항' 및 '이음형 표준 루브릭'을 개발·적용한다.

다. AI 채점 시스템을 활용한 ‘교사-AI 협업 평가체제’를 구축하고, 1년간의 집중 운영을 통해 그 효율성과 신뢰성을 실증적으로 검증한다.

라. 소규모 학교의 강점을 살려 개발한 연구 성과(평가 모델, 문항 사례, AI 협업 매뉴얼 등)를 자료집으로 제작·공유하여 확산 가능한 일반화 방안을 제시한다.

3 연구의 범위 및 제한점

가. 연구의 범위

영 역	내 용
연구 기간	2026. 3. 1. - 2027. 2. 28.(1년)
연구 대상	전 교원(14명) 및 학생(66명)
연구 내용	‘이음 교육과정’과 연계한 ‘이음-평가 모델’ 구축 ‘교실-삶 이음’ 서·논술형 문항 및 ‘이음형 표준 루브릭’ 개발 ‘교사-AI 협업’ 평가 모델 구축 및 검증

【표 1】 연구의 범위

나. 연구의 제한점

본 연구는 1개 소규모 학교를 대상으로 1년간 진행되어 연구 결과의 정량적 일반화와 통계적 유의성에는 명백한 한계가 있다. 이에 따라 본 연구는 정량적 성과의 제시가 아니라 ‘교사-AI 협업 모델’의 개발 과정, ‘교실-삶 이음 서·논술형 평가 문항’의 질적 수준, ‘이음형 표준 루브릭’의 정교함, 실무 매뉴얼의 구체성 등 타 학교가 즉시 참고할 수 있는 질적으로 우수한 콘텐츠를 개발·검증하는 데 연구 역량을 집중하였다.

아울러 실질적인 연구 운영 기간은 약 8개월에 불과하여, 2학기 전체 운영 결과와 교사-AI 채점 원자료의 전면적인 취합·분석까지 마무리하기에는 시간적 제약이 있었다. 이에 본 보고서는 이미 확정된 1학기 실적과 2학기 진행 현황을 결과로 명확히 구분하여 제시하고, 11월 이후로 예정된 활동은 결과가 아닌 향후 계획으로 별도 표기하였다.

4 연구 용어의 정의

용 어	정 의(뜻)
이음-평가 모델	본교의 ‘이음 교육과정’을 기반으로 설계된 미래형 학생평가 모델로, ‘교육과정-수업-평가-피드백’의 유기적 이음(연계)과 학생의 깊이 있는 이해, 의미 있는 AI 활용을 핵심 원리로 하는 성장 중심의 평가 체제

교실-삶 이음	2022 개정 교육과정의 비전을 이음 교육과정에 적용하는 핵심 원리로, 교실에서 배운 지식·개념을 학생의 실제 삶의 맥락과 연결하는 탐구 질문을 중심으로 평가를 설계하는 방식
교사-AI 협업	교사가 교육과정·수업·학생 맥락을 바탕으로 평가 목적과 기준을 설계하고, 교사와 AI가 동일 답안을 각각 독립적으로 판단한 뒤 점수·채점 근거·피드백을 비교·검토하여 교사가 최종 판단하는 협력적 평가 체제. 향후 평가요소의 성격에 따른 역할 분담 가능성을 탐색하되, 현재 운영에서는 병행채점과 상호 검토를 중심으로 함
이음형 표준 루브릭	성취기준과 평가요소에 근거하여 학생의 수행 수준을 일관되게 판단하도록 설계한 채점 기준표. 1학기에는 정량·정성 분리형을 시도하였으나, 2학기에는 평가요소의 성격과 인지적 요구 수준에 따라 통합된 기대수행을 진술하는 방식으로 개선함

【표 2-1】 용어 정의

아래 4개 용어는 계획서에는 없었으나, 1학기 운영 과정에서 새롭게 정립되어 이후 Ⅳ~Ⅷ장에서 반복적으로 사용되는 실행 결과 용어이므로 함께 정의하여 제시한다.

용 어	정 의(뜻)
단계형 비계 질문	학생이 하나의 복합적인 사고 과정을 실제로 수행 가능한 작은 사고 단위로 나누어 순차적으로 경험하도록 설계한 보조 질문. 모든 답을 점수화하지 않고, 앞부분의 비계 질문은 학습과 피드백을 위해 활용하며 성취기준·평가요소와 직접 연결된 핵심 평가 질문의 답안만 점수화하는 것을 기본 원리로 함
과정중심평가 집중운영기간	교과별 수행평가 시기가 비계획적으로 몰리는 것을 방지하기 위해 설정한 약 1주일간의 기간으로, 이 기간에는 교과별로 최대 1개 영역의 수행평가만 실시하고 학교 행사도 가급적 배치하지 않음
이음형 표준 루브릭(통합형)	1학기 정량·정성 분리형 루브릭의 한계를 보완하여, 평가요소의 성격에 따라 필요한 경우에만 정량 기준을 병기하고 나머지는 하나의 기대수행 진술로 통합 제시하는 2학기 개선형 루브릭 형식
핵심 평가 질문	단계별 비계 질문을 통해 형성된 학생의 사고를 성취기준 및 평가요소와 직접 연결하여 확인하는 질문. 비계 단계의 모든 활동을 점수화하지 않고 핵심 수행만 루브릭으로 평가함

【표 2-2】 용어 정의(추가)

Ⅱ 이론적 배경

1 관련 이론

가. 2022 개정 교육과정의 '깊이 있는 학습'

2022 개정 교육과정은 지식의 단순 전달이 아니라 학생이 학습의 전 과정에 주도적으로 참여하여 핵심 개념과 원리를 깊이 있게 이해하는 '깊이 있는 학습'을 강조한다. 이는 학습 내용을 자신의 삶과 연계하여 새로운 맥락에 적용하고 문제를 해결하는 실천적 역량으로 이어져야 함을 뜻하며, 학습의 결과뿐 아니라 과정을 중시하는 과정중심평가 및 서·논술형 평가의 확대를 요구한다. 본 연구는 이 원리를 '교실-삶 이음'이라는 문항 설계 관점으로 구체화하였다.

나. 성취평가제와 과정중심평가의 연계

성취평가제는 학생이 교육과정을 통해 무엇을, 어느 정도 성취하였는지를 성취기준에 따라 판단하는 평가 방식이며, 과정중심평가는 수업 과정에서 학생의 변화와 성장에 대한 자료를 다각적으로 수집하여 적절한 피드백을 제공하는 평가이다. 본 연구의 '이음-평가 모델'은 이 두 제도를 근간으로, 이음 교육과정의 성취기준을 학생의 삶의 맥락 속에서 평가하고 그 과정과 결과를 성장을 위한 구체적인 피드백으로 환류하는 것을 지향하였다. 다만 성취평가제의 성취수준(A~E)은 결과 판정의 준거로서는 명확하지만, 그 자체만으로는 '어떤 과정을 거쳐 해당 수준에 이르렀는가'를 드러내지 못한다는 한계가 있다. 본 연구가 문항 설계 단계에서 탐구질문과 단계별 비계 질문을 결합하고자 한 것은, 성취기준-성취수준이라는 결과 중심의 틀에 학생의 사고 과정을 드러내는 과정중심평가적 요소를 접목하여 두 제도의 장점을 함께 살리려는 시도였다.

접 근	특징	본 연구의 입장
완전 수동 채점	교사가 모든 서·논술형 답안을 단독으로 채점. 채점의 질적 판단은 확보되나 시간·업무 부담이 매우 큼	현행 다수 학교의 방식이나, 서·논술형 확대 시 지속 가능성에 한계
완전 자동 채점	AI가 답안을 채점하고 교사는 결과만 확인. 채점 속도는 빠르나 고차원적 판단(독창성, 가치판단 등)의 정확성 담보 곤란	본 연구가 채택하지 않는 방향 — 교사의 평가 전문성이 배제될 위험이 있음
교사-AI 협업 채점	교사와 AI가 동일 답안을 독립적으로 채점하고 점수·채점 근거·피드백을 비교함. 교사는 불일치 원인을 검토한 뒤 최종 점수를 확정하고, AI는 제2의 채점자이자 판단 점검 도구로 기능함	본 연구의 실제 운영 방식. 평가요소별 역할 분담은 가능성을 확인했으나 1년의 짧은 운영기간을 고려하여 이번 연구에서는 독립병행채점과 비교·검토를 중심으로 검증함

【표 3】서·논술형 채점 방식의 세 가지 접근

다. AI기반 서·논술형 평가 시스템과 '교사-AI 협업' 모델

본 연구는 AI 채점의 완전 자동화를 목표로 하지 않았다. 계획 단계에서는 정형적·정량적 영역은 AI가, 고차원적·정성적 영역은 교사가 상대적으로 더 큰 역할을 담당하는 구조를 상정하였으나, 실제 운영에서는 그 경계를 사전에 고정하기 어려웠다.

이에 1학기에는 교사와 AI가 동일한 학생 답안을 각각 독립적으로 채점한 뒤 점수와 채점 근거를 비교하고, 교사가 최종 판단하는 병행채점 방식을 중심으로 검증하였다. 이 과정에서 AI는 교사의 판단을 대체하는 자동채점자가 아니라, 교사의 판단을 재검토하게 하는 제2의 채점자이자 평가도구의 모호성을 드러내는 점검 도구로 기능하였다.

2 선행 연구 분석 및 본 연구의 차별성

본 연구는 계획 단계에서 국가 수준의 AI 기반 평가 관련 선행 연구를 검토하여 본 연구의 방향을 설정하는 근거로 삼았다.

연구 주제	선행 연구 내용(요약)	본 연구와의 차별성 및 시사점
국가수준 학업성취도평가의 CBA 전면 도입과 AI 기반 학력진단 (한국교육과정평가원 2022)	학생별·영역별 진단 빅데이터를 바탕으로 AI 기반 학력진단시스템을 단계적으로 구축한다는 추진 방향을 제시하고 실제 맥락형 문항으로 문제해결력 측정을 강조해 서·논술형/구성적 반응의 문항 확장 기반을 마련함.	AI를 활용한 채점 자동화보다는 AI를 통한 평가 결과 분석 및 진단에 초점을 맞추고 있음. 단 교사-AI 협업 모델이 추구하는 학생 맞춤형 피드백의 기반을 확인할 수 있음.
컴퓨터 기반 서·논술형 평가를 위한 자동채점 방안 설계 (한국교육과정평가원 2023)	서·논술형 문항의 자동채점 절차를 체계화하고 시범 적용을 통해 인간 채점과의 일치도·공정성 검증 프레임을 제시함.	서·논술형 문항의 자동 채점의 메커니즘을 확인하고 인간 채점과의 차이를 분석하는 유의미한 자료를 제공함. 단, 교육과정-수업-평가-피드백으로 이어지는 일반화된 평가 모델은 제시하지 않음.
생성형 인공지능 기반 피드백 제공 서술형 평가 도구 개발 및 교육과정 효과분석 (서울대학교 교육전문대학원 석사학위 논문 2024)	생성형 인공지능을 활용하여 초등학교 사회과 서술형 평가에 대한 자동 채점 및 개별 피드백을 제공하는 웹 기반 도구를 개발하고 결과를 분석한 결과 비교적 높은 신뢰도와 타당도를 확인함.	초등학교 1개 교과의 서술형 평가 문항을 대상으로 하여 인공지능을 통한 채점 결과를 분석한 것으로 본 연구의 교사-AI협업 모델 구현을 위한 인공지능의 채점 역량을 확인할 수 있는 자료를 제공함.

【표 4】 선행 연구 분석

본 연구는 위 선행 연구들이 개별적으로 다룬 'AI 데이터 수집', '서·논술형 평가 AI 자동채점', 'AI 평가 맞춤형 피드백'이라는 주제를 넘어, 이음 교육과정과 소규모 학교라는 연구 여건을 기반으로 2022 개정 교육과정, 삶과 연계된 평가, 교사-AI 협업 모델을 하나로 잇는 통합 모델을 1년간 실제 운영하며 검증하였다는

점에서 차별성을 갖는다. 다만, 실제 운영 과정에서 이 차별성은 계획 단계에서 상정한 ‘AI 활용 방법의 표준화’ 보다는 ‘평가 설계 원리의 정립’ 쪽으로 구체화 되었다.

Ⅲ 실태 분석 및 연구과제 설정

2026학년도 학생평가 연구학교 운영의 기초 자료를 마련하기 위해 2025년 11월과 2026년 3월 두 차례에 걸쳐 본교 교사·학생을 대상으로 설문조사를 실시하고 학교 현황을 분석하였다. 이 결과는 연구과제 설정의 근거이자, 사전-사후 인식 변화 분석의 기준선으로도 함께 활용하였다.

1 학교 현황(SWOT 분석)

Strength [강점]	○ 2022-2025 '서로나눔학교' 운영 경험 및 성과 축적 ○ 2026 '서로나눔학교(자율학교)' 재지정 확정 및 '이음 교육과정' 비전 공유 ○ 혁신학교 운영을 통해 축적된 교사들의 높은 혁신 의지, 자발성, 전문적 학습 공동체의 활성화 ○ 소규모 학교의 특성 -교사 1인당 학생 수가 적어 심층적·질적 연구 수행에 최적화 -유연한 교육과정 운영 및 밀도 높은 질적 피드백 제공에 절대적 우위
Weakness [약점]	○ 학생 수가 절대적으로 적어, 연구 결과의 '정량적 데이터' 수집 및 '통계적 유의성' 확보에 명백한 한계가 있음
Opportunity [기회]	○ 2022 개정 교육과정의 '서·논술형 평가 확대'라는 강력한 정책적 요구 ○ AI기반 평가 시스템에 대한 국가적 관심 및 기술 지원 확대 ○ 연구학교 지정을 통해 이음 교육과정 안착에 필요한 인적·물적 자원 및 동력 확보
Threat [위협]	○ 1년 이라는 단기 운영 기간으로 인해 가시적 성과 도출에 대한 압박 존재 ○ 서·논술형 평가 확대에 따른 학부모의 공정성 및 객관성 확보 요구 증대 ○ AI시스템의 기술적 오류 또는 낮은 신뢰도 발생 시, 교사들의 저항 및 불신 초래 가능성

【표 5】 학교현황(SWOT 분석)

2 실태 분석 및 시사점

2026년 3월 실시한 설문에는 교원 14명 중 12명, 학생 66명 중 62명이 참여하였다. 주요 결과는 다음과 같다.

유형	질 문(요 약)	결 과(%)	분석 내용
교사 학생 공통 질문	사고 과정을 평가하는데 가장 적합한 평가 유형은?	교사 : 서·논술형 91.7 학생 : 서·논술형 50	교사와 학생 모두 학생의 고등 사고 과정을 평가하는데 서·논술형 평가가 적합하다는 데 공감함.
	학교의 수업 및 평가가 실제 삶과 연결이 되는가?	교사 : 보통 50, 그렇다 30 학생 : 보통 32.3, 아니다 24.2	학교의 수업 및 평가가 실제 삶과 연결되는 데 확신을 갖지 못하는 경향을 보였으며, 학생의 경우 그 경향이 더 크게 나타남.
	AI가 채점을 할 경우 가장 우려되는 점은?	교사 : 채점오류 33, 기술적 어려움 25 학생 : 채점오류 71, 정보유출 11	교사와 학생 모두 AI 채점의 오류에 대해 우려를 나타냄.

학생 개별 질문	평가 후 피드백은 적절하게 이루어지는가?(관련 문항 2개)	보통 32.3 더 많은 피드백 필요 24.2	학생들은 자신들의 학습 수준에 맞는 더 많은 피드백이 필요하다고 느끼고 있음.
교사 개별 질문	서·논술형 평가 확대 시 가장 우려되는 점은?	채점 부담 50, 문항 개발 41.7	채점에 대한 부담이 가장 크며 문항개발, 채점의 공정성 순으로 우려를 나타냄.
	(서술형 문항) 미래형 학생 평가를 위해 교사에게 요구되는 가장 필요한 역량은?	2022 개정 교육과정에 대한 이해도, 서·논술형 평가 역량, AI 및 디지털 도구 활용 역량, 업무량 감소, 기술적 지원 등을 요구함.	

【표 6】 실태 분석

실태 분석 결과 교사와 학생 모두 서·논술형 평가 확대의 필요성 및 삶 연계의 중요성, 질적 피드백에 대한 요구가 매우 높게 나타났다. 그러나 이를 가로막는 핵심 장애 요소는 교사의 과중한 채점 업무 부담과 평가 결과의 공정성·신뢰도 문제로 귀결되었다. 이에 본 연구는 '정량적 데이터' 수집이 아닌 '질적 모델 개발'에 최적화된 소규모 학교의 강점을 집중하여, ① 이음 교육과정 철학에 기반한 '이음-평가 모델'과 '교실-삶 이음' 서·논술형 문항을 통해 평가의 교육적 타당성과 삶 연계성을 제고하고, ② '교사-AI 협업' 모델을 통해 평가의 신뢰성과 효율성을 동시에 확보하는 것을 연구의 축으로 삼았다.

실태 분석에서 확인된 요구	관련 지표【표 6】	대응 전략
서·논술형 평가에 대한 높은 공감	교사 91.7% / 학생 50%	정기시험·수행평가 반영 비율 확대
수업·평가와 삶의 연계 부족 인식	교사 보통 50% / 학생 보통 32.3%	'교실-삶 이음' 탐구질문 중심 문항 개발
AI 채점 오류에 대한 우려	교사 33% / 학생 71%	교사-AI 병행 채점 및 신뢰도 검증
더 많은 피드백에 대한 요구	보통 32.3% / 필요 24.2%	단계별 비계 질문 및 2학기 피드백 강화 계획
채점 부담에 대한 교사의 우려	채점 부담 50%	AI·디지털 환경 조성 및 정기시험 축소

【표 7】 실태 분석에서 확인된 요구와 대응 전략

3 연구과제 설정

가. [과제 1] 미래형 학생평가 운영을 위한 학교 여건 조성

- ○ '이음-평가 모델' 개발 및 공감대 확대
- ○ 서·논술형 평가 확대 운영을 위한 학업성적관리규정 및 평가운영방식 개선
- ○ '교사-AI 협업'을 위한 AI·디지털 교육 환경 조성
- ○ 교원의 평가 전문성 및 역량 신장을 위한 집중 연수 및 컨설팅 운영

나. [과제 2] '이음교육과정' 기반 미래형 학생평가 '이음-평가 모델' 구축

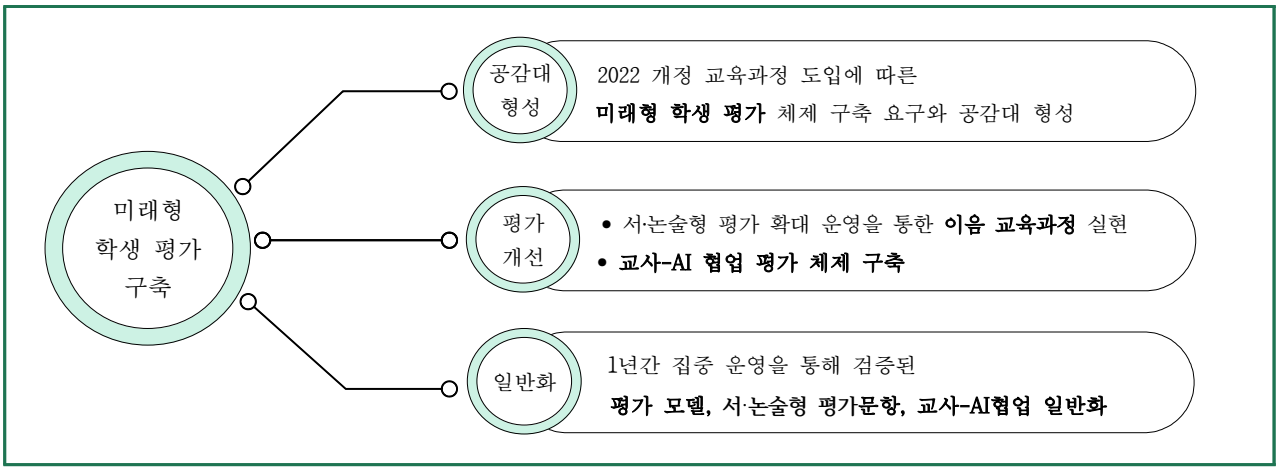
- ○ '이음-평가 모델' 실행 로드맵 수립 및 적용
- ○ '교실-삶 이음' 기반의 서·논술형 평가 문항 개발

○ 학생의 성장을 돕는 ‘이음형 표준 루브릭’ 개발
○ ‘이음-평가 모델’ 현장 적용 및 수업-평가-피드백 사례 축적

다. [과제 3] ‘교사-AI 협업’ 평가 체제 구축 및 검증

○ ‘교사-AI 협업’ 서·논술형 평가 시스템 개발 및 교사 활용 실무 연수
○ ‘이음형 표준 루브릭’ 기반의 AI 채점 프로세스 확립
○ 채점 결과 비교 분석을 통한 평가의 신뢰도 및 타당성 검증

□ 연구과제 실행 조직도



【표 8】 연구과제 실행 조직도

정리하면, 학교 현황 분석(SWOT)과 구성원 실태 조사는 서로 다른 방법으로 수집된 자료임에도 같은 결론을 가리키고 있었다. 즉 서·논술형 평가 확대의 필요성과 삶 연계 강화에 대한 공감대는 이미 충분히 형성되어 있었으나, 이를 실행에 옮기는 데는 교사의 채점 부담과 평가 신뢰도라는 두 가지 실질적 장애물이 가로막고 있었다는 것이다. 3개 연구과제는 이 두 장애물을 각각 정면으로 겨냥하도록 설계되었다.

Ⅳ 운영의 설계

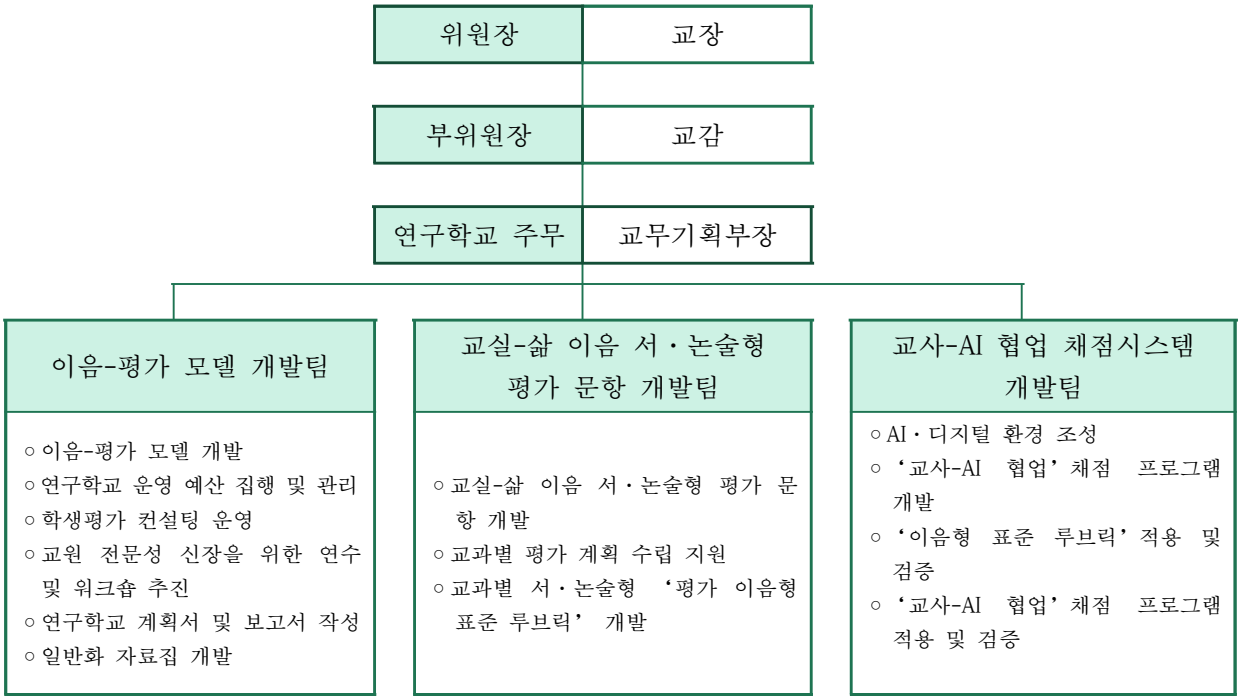
1 연구 추진 일정

연구학교 운영 계획서는 2월 조직 구성을 시작으로, 1차 적용 및 개발(4~5월)·2차 적용 및 개발(6~7월)·중간 검증(8월)·2차 심화 적용 및 검증(9~10월)·일반화(11~1월)에 이르는 6단계 일정을 계획하였다.

단계	월	주요 내용	과제1	과제2	과제3
기반 구축	2	○ 연구 T/F 조직	◎		
	3	○ 연구학교 계획 단계 컨설팅(교육청) ○ 2022 개정 교육과정 및 성취평가제 심화 연수 ○ 학업성적관리규정 및 평가운영방식 개선 ○ AI·디지털 환경 조성 ○ '이음-평가' 모델 개발 및 공감대 확대 ○ '교실-삶 이음' 서·논술형 평가 모델 개발	◎	◎	
1차 적용 및 개발	4	○ 서·논술형 평가 문항 및 루브릭 개발 연수 ○ 교과별 '교실-삶 이음' 논술형 수행평가 문항 개발 ○ '교사-AI 협업' 평가 채점 시스템 개발(도입) 및 연수		◎	◎
	5	○ 교과별 '이음형 표준 루브릭' 개발 ○ 서·논술형 수행평가 실시 및 채점			
2차 적용 및 개발	6	○ 에듀테크 및 AI 활용 학생 평가 연수 ○ '교사-AI 협업' 평가 채점 시스템 적용 및 정교화 ○ 교과별 '이음형 표준 루브릭' 적용 및 정교화		◎	◎
	7	○ 연구학교 실천 단계 컨설팅(교육청) ○ 중간 보고회			
중간 검증	8	○ '교사-AI 협업' 채점 시스템 검증 ○ 교과별 '이음형 표준 루브릭' 검증		◎	◎
2차 심화 적용 및 검증	9	○ 연구학교 결과 단계 컨설팅(교육청) ○ 교과별 '이음-평가' 서·논술형 평가 문항 고도화 ○ 교과별 '이음형 표준 루브릭' 심층 검증 및 고도화 ○ '교사-AI 협업' 평가 채점 시스템 고도화 ○ 최종 데이터 분석 ○ 만족도 조사 실시		◎	◎
	10				
검증 및 일반화	11	○ 일반화 자료집 제작 ○ 최종 성과 보고회 실시			◎
	12				
	1				

【표 9】 연구 추진 일정

2 연구 운영 조직(이음 T/F 팀)



【표 10】 연구 운영 조직

본교와 같은 소규모 학교는 교과별 담당 교사가 1명인 경우가 많아 일반적인 동교과 협의회를 구성하기 어렵다. 이에 국어·영어·수학·과학·사회(역사) 담당 교사가 함께 참여하는 공동 협의 체제를 T/F 운영의 실제 방식으로 채택하였다. 서로 다른 교과 교사가 참여함으로써 타 교과 교사가 전문 내용까지 깊이 판단하는 데는 한계가 있었으나, 출제자 본인에게는 당연해 보였던 질문이 다른 교과 교사에게는 모호하게 느껴지는 지점을 짚어주는 등 문항을 학습자 관점에서 다시 점검하는 데는 실질적인 도움이 되었다. 예컨대 수학 교과는 서·논술형 평가를 풀이 과정 서술로 좁게 접근하는 경향이 있었으나, 공동 협의를 통해 풀이 과정을 선택한 이유를 설명하게 하거나 수학적 원리가 담긴 일상 사례를 찾아 비교하게 하는 방식으로 문항의 폭을 넓히는 계기를 얻었다.

차수	일자	주제	주요 결정 사항
1차	3/13(금)	연구학교 운영 방향 수립	정기시험 학기 1회, 정기시험 40%/수행평가 60%, 서술형 40% 이상 등 평가운영방식 개선안 확정
2차	5/13(수)	평가도구·채점 프로그램 개선	자체개발 채점 프로그램의 한계 확인 → AI 채점 시스템 '클리포' 도입 결정
3차	5/22(금)	클리포 활용 피드백	OCR 방식 전환, 정성·정량 통합형 루브릭으로 개선 결정, 업무 분담 조정
4차	6/15(월)	교실-삶 이음 서·논술형 평가 문항 개선	1학기 문항 적용 결과 점검 및 2학기 문항 개선 방향 논의
5차	7/21(화)	1학기 결과 점검 및 2학기 계획 수립	단계별 비계 질문 도입, 정기시험 서·논술형 비율 확대, 루브릭 표준안 등 2학기 개선안 확정

6차	9/22(화)	학생 평가 연구학교 2학기 운영 협의	교과별 교실-삶 이음 서·논술형 문항에서 비계 질문과 핵심 평가 질문의 구분, 루브릭 연계성 공동 검토
7차	10/7(수)	학생 평가 연구학교 운영 내용 취합	학생평가 연구학교 보고서 작성을 위한 자료 취합 및 분석 사후 설문 문항 협의

【표 11】 협의회 운영 결과

협의회 운영 결과가 보여주듯, 1차 협의회에서 운영 방향을 수립한 뒤 2~3차 협의회에서 채점 도구 자체를 재검토·전환하고, 4~5차 협의회에서 문항·평가 방식을 개선하는 흐름은 전형적인 실행연구의 계획-실행-관찰-성찰 순환 구조를 따른다. 2학기에는 이 순환을 이어 6차 협의회에서 교과별 단계별 비계 문항과 핵심 평가 질문을 공동 검토하고, 7차 협의회에서 사후 설문 문항을 협의하여 연구의 질적 관찰을 정량적 자료와 연결하였다.

1학기 5회 협의는 ① 연구학교 방향 공유 → ② 자체개발 프로그램 활용 방안 논의 → ③ 채점 전 클리포 활용 및 평가계획 점검 → ④ 채점 후 교사-AI 결과 분석 및 평가도구 개선 → ⑤ 1학기 운영 종합 평가와 2학기 개선안 도출의 흐름으로 운영되었다. 2학기 6·7차 협의 역시 학교 차원의 공통 원리와 교과별 자율성을 조화시키는 방식으로 운영하였다.

요약하면, 본교의 연구 운영 조직은 계획서상의 위원장-부위원장-주무-3개 팀이라는 공식 조직도와, 실제로는 교과 공동 협의체가 상시적으로 가동되는 이중 구조로 운영되었다. 공식 조직도가 예산·연수 등 행정적 의사결정의 책임 소재를 명확히 하는 역할을 하였다면, 교과 공동 협의체는 문항·루브릭 개발이라는 연구의 실질적 내용을 채워나가는 역할을 하였다.

V 연구과제 실행 결과

연구학교 계획서에서 설정한 3개 연구과제 ① 미래형 학생평가 운영을 위한 학교 여건 조성, ② ‘이음-평가 모델’ 구축, ③ ‘교사-AI 협업’ 평가 체제 구축 및 검증은 계획대로 순차 진행되었으나, 실제 운영 과정에서 세부 과제 간 우선순위와 강조점에는 계획 단계와 다른 조정이 있었다.

과제1 미래형 학생 평가 운영을 위한 학교 여건 조성

가. ‘이음-평가’ 모델 개발 및 공감대 확대

2월 연구학교 운영 T/F팀(이음 T/F)을 조직하고, ‘교실-삶의 이음’과 ‘생각-행동의 이음’이라는 이음 교육과정의 핵심 가치를 학생평가에 구현하는 원리를 도출하는 작업을 시작하였다. 1차 연수(2/23, 내부강사, 교원 14명 대상)를 통해 연구학교 운영 중점 과제를 전 교원에게 안내하였고, 2차 연수(4/2, 학교공개의날과 병행)는 교원 14명뿐 아니라 학생 66명, 학부모 16명까지 대상을 확대하여 실시함으로써 평가 방식 변화에 대한 학교 구성원 전체의 공감대를 넓히고자 하였다.

다만, 계획 단계에서는 ‘AI를 평가에 어떻게 도입·활용할 것인가’가 연구의 핵심 과제로 설정되어 있었으나, 실제 적용을 거치면서 연구의 중심은 ‘평가도구 자체의 설계 원리’로 이동하였다. 성취기준에 근거한 평가요소 설정, 학생의 사고를 드러내는 문항 설계, 성취수준을 판별할 수 있는 루브릭의 정교함이 먼저 갖추어지지 않으면 AI를 아무리 정교하게 활용하더라도 채점의 질을 높이는 데 한계가 있다는 점을 실행 초기에 확인하였기 때문이다. 이에 따라 본교는 ‘AI 활용 방법의 표준화’가 아니라 ‘성취기준 분석 → 평가요소 도출 → 탐구질문 개발 → 단계별 비계 질문 개발 → 루브릭 개발’로 이어지는 평가 설계 절차의 정립을 공통 원리로 삼고, AI는 그 절차 안에서 교과와 교사의 필요에 따라 유연하게 활용하는 방향으로 연구의 초점을 조정하였다. 연구 주제인 ‘교사-AI 협업’이라는 표현 자체는 그대로 유지하되, 그 의미를 ‘AI가 평가를 대신하는 것이 아니라 교사가 설계한 목적과 기준 안에서 AI가 교사의 판단을 지원하는 체제’로 구체화한 것이 1학기 운영을 통해 도출된 핵심적인 방향 전환이다.

요 약

세부 과제	시기	실행 결과	산출물
‘이음-평가’ 모델 개발 및 공감대 확대	2~4월	○ 연구학교 T/F 팀 조직 ○ 1·2차 연수를 통한 전 구성원 공감대 확산 ○ 연구 중심축을 ‘AI 활용’에서 ‘평가 설계 원리’로 재정립	이음-평가 연구학교 운영 계획서

【표 12】 세부 과제 1-가 요약

□ **서·논술형 평가에 대한 인식 변화**

본 연구를 통해 확인된 가장 큰 성과를 하나 꼽는다면 서·논술형 평가를 바라보는 교사와 학생의 인식 변화라고 할 수 있다. 연구 이전에도 다수의 교사는 서·논술형 평가가 학생의 성취수준을 판단하는 데 적절하고 성취평가제의 취지에도 부합한다는 점에는 동의하고 있었다. 그러나 구체적으로 어떤 서·논술형 평가가 학생의 성장을 실질적으로 돕는지에 대해서는 공통된 이해와 경험이 부족한 상태였다.

하지만 연구가 진행되면서 교사는 서·논술형 평가를 단순히 학생에게 긴 글을 쓰게 하는 평가로 보지 않게 되었고, 학생 또한 글쓰기 자체에 대한 막연한 두려움을 낮추며 자신의 생각을 글로 표현할 수 있다는 경험을 쌓아가기 시작하였다.

이러한 인식 변화의 양상은 교과군에 따라 다르게 나타났다. 국어·사회·영어와 같은 인문교과는 기존에도 서·논술형 평가를 비교적 자주 실시해왔기 때문에 평가 유형 자체에 대한 부담은 크지 않았고, 변화는 주로 문항 개발의 체계성과 정교성에서 나타났다. 반면 수학·과학 교과는 처음에는 서·논술형 평가를 '자신의 생각이나 주장을 글로 쓰게 하는 평가'로 받아들이는 데 부담을 느끼는 경향이 강했다. 특히 수학과는 서·논술형 문항을 풀이 과정 서술 정도로 좁게 이해하는 시각이 있었으나, 교과 공동 협의를 통해 다른 교과의 사례와 조언을 접하면서 왜 그러한 풀이 과정을 선택했는지 설명하게 하거나 수학적 원리가 적용된 일상 사례를 찾아 비교하게 하는 방식으로 서·논술형 평가의 범위를 넓게 이해하게 되었다.

이 경험에 비추어 볼 때, 서·논술형 평가는 학생에게 긴 글을 쓰게 하는 평가가 아니라 교과에서 배운 지식을 바탕으로 자신의 생각을 형성하고 근거 있게 표현하며 삶과 세상을 이해하도록 돕는 평가로 재규정될 필요가 있다. 서·논술형 평가의 양적 확대보다 먼저 필요한 것은 서·논술형 평가 자체를 바라보는 인식의 변화라는 것이, 1년간의 운영을 통해 본교가 확인한 가장 중요한 시사점이다.

나. 서·논술형 평가 확대 운영을 위한 학업성적관리 규정 및 평가운영방식 개선

2022 개정 교육과정과 서·논술형 평가 확대를 실질적으로 뒷받침하기 위해, 2026 학업성적관리시행지침을 토대로 본교의 2026학년도 학업성적관리규정과 평가 운영 방식을 개선하여 적용하였다.

□ 평가운영 방식 개선 내용

영역	변경 전	변경 후
정기시험	○ 학기별 2회(중간/기말고사) 실시 ○ 서·논술형 평가는 정기시험 총 배점의 20% 이상 포함	○ 학기별 정기시험(학기 고사) 1회 실시 ○ 서술형 평가는 정기시험 총 배점의 40% 이상 포함(서술형 평가와 논술형 평가를 분리하고 정기시험에 서술형평가 포함)
수행평가	○ 학기별 수행평가 2개 영역 실시	○ 학기별 수행평가 2개 영역 이상 실시 ○ 수행평가 2개 영역 중 1개 영역은 논술형 평가 실시

		○ 과정중심평가(수행평가) 집중 운영 기간 운영
반영비율	○ 정기시험 60%(중간 30%, 기말 30%) ○ 수행평가 40%	○ 정기시험 40% ○ 수행평가 60%

【표 13】 평가운영 방식 개선

개선안은 학기 초 교사·학생·학부모의 의견을 수렴한 뒤 학교 설명회(4/2 학교공개의 날)와 가정통신문을 통해 안내되었으며, 사전 설명에 서·논술형 평가 확대와 AI 채점에 대해 예상되는 우려와 질문을 미리 포함하여 안내한 결과 현장에서 별다른 이의 제기 없이 대체로 공감하는 분위기에서 수용되었다.

정기시험을 학기 2회에서 1회로 줄인 결정은 단순한 시험 횟수 조정 이상의 의미를 가졌다. 본교처럼 교과별 담당 교사가 1명인 소규모 학교에서는 한 교사가 3개 학년의 정기시험 문항을 모두 출제하고 학년별 수행평가 2개 영역까지 준비해야 하는 구조적 부담이 있었는데, 정기시험을 1회로 줄이면서 확보된 시간을 수행평가를 더 깊이 있게 설계·검토하고 채점 전후 협의회를 운영하는 데 사용할 수 있었다. 실제로 시험 범위와 문항 구성에 맞춰 암기·반복 학습을 강조하던 수업 방식에서도 어느 정도 벗어날 수 있었다는 것이 현장의 평가이다. 다만 평소 학습 동기가 낮았던 일부 학생에게는 시험을 앞둔 외적 학습 동기가 줄어드는 부작용도 함께 관찰되었으며, 인근 학교와 시험 일정이 달라져 학원 등 외부 학습 일정과 어긋나는 불편이 발생하기도 하였다.

아울러 수행평가가 특정 시기에 비계획적으로 몰리는 문제를 방지하기 위해 별도의 '과정중심평가 집중운영기간'(약 1주간)을 설정하여, 이 기간에는 교과별로 최대 1개 영역의 수행평가만 실시하고 학교 행사도 가급적 이 기간을 피하도록 운영하였다. 이 기간 전후로 채점 전 협의회(평가계획·AI 채점 방법 점검)와 채점 후 협의회(결과 분석 및 개선안 논의)를 배치함으로써, 정기시험 축소로 확보한 시간이 실제 평가의 질 개선으로 이어지도록 설계하였다.

요 약

세부 과제	시기	실행 결과	산출물
서·논술형 평가 확대 운영을 위한 학업성적관리규정 및 평가운영방식 개선	3월	○ 2026학년도 학업성적관리규정 개정 ·평가운영방식 개선안 포함 ○ 학생평가 운영 방식 안내(학생, 학부모)	2026학년도 학업성적관리 규정 및 평가계획서

【표 14】 세부 과제 1-나 요약

다. '교사-AI 협업'을 위한 AI·디지털 교육환경 조성

계획 단계에서는 기존에 개발되어 있는 AI 서·논술형 평가 채점 시스템을 검토·선정하는 방향을 상정하였으나, 실제 운영 초기에는 구글 시트 기반으로 채점 자동화 체계를 자체 개발하여 활용하였다. 이후 교과별 활용 범위를 넓히는 과정에서 자체 개발 도구의 한계가 확인되어, 바이브 코딩을 통해 API와 HTML 기반의 웹 애플리케이션으로 재구성하는 시도를 거쳤다.

그러나 수식·그림·도형이 포함된 답안이나 손글씨 답안의 인식 등 자체 개발 도구만으로는 안정적으로 해결하기 어려운 기술적 한계가 반복적으로 나타남에 따라, 2차 협의회(5/13)에서 OCR 기능을 갖춘 상용 AI 서·논술형 평가 채점 시스템 '클리포'를 도입하기로 결정하였고, 3차 협의회(5/22)에서 채점 방식을 클리포 중심으로 전환하였다. 전 교사 업무용 PC의 AI 프로그램 구동 환경과 학생용 태블릿·전 교실 무선 인터넷 환경 점검도 함께 진행하였다.

자체 개발 프로그램의 구체적인 변천 과정은 다음과 같다. 최초 버전은 Google Apps Script와 Google Sheet를 기반으로, Gemini·GPT API를 연동하여 성취기준·성취수준을 재구성하고 이를 바탕으로 교실-삶 이음 서·논술형 문항과 루브릭을 생성한 뒤, Google Forms로 받은 학생 답안을 채점하고 피드백·교과세특 초안까지 산출하는 통합 흐름을 구현하고자 하였다.

그러나 구글 시트 중심의 UI·UX가 교사 입장에서 접근성이 낮았고, API를 통해 호출한 AI의 성능도 해당 플랫폼을 직접 사용할 때보다 기대에 못 미쳤으며, 학생이 구글 폼에 답안을 직접 입력해야 하는 방식 자체도 현장 활용성에 한계가 있었다. 이에 바이브 코딩을 활용해 API와 HTML 기반으로 재구성한 두 번째 버전은 중학교 전 교과에서 활용할 수 있도록 성취기준 분석·평가요소 도출을 거쳐 교실-삶 이음 탐구질문과 단계별 질문을 개발하는 흐름을 중심으로 재설계하였으며, 학교 누리집에 게시하여 상시 활용할 수 있도록 하였다(다만 별도 백엔드를 두지 않아 실제 사용 통계는 확인되지 않는다). 이 두 버전의 개발·운용 경험이 최종적으로 상용 OCR 채점 시스템 도입의 필요성을 뒷받침하는 근거가 되었다.

한편 실제 교사들이 자체 개발 프로그램만을 사용한 것은 아니다. API 성능이나 사용 편의성의 한계로 인해 GPT·Gemini·Claude 등 범용 생성형 AI 플랫폼을 직접 사용하거나, 맞춤형 챗봇(GPTs, Gems 등)을 활용하는 교사도 상당수였다. 이는 프로그램을 하나로 통일하는 것보다, 성취기준 분석-평가요소 도출-탐구질문 개발-루브릭 개발이라는 공통된 평가도구 개발 절차 안에서 교과와 교사 상황에 맞게 AI를 유연하게 활용하도록 하는 것이 더 현실적이라는 판단으로 이어졌으며, 이는 'AI 활용의 표준화'가 아닌 '평가 설계 절차의 정립'이라는 연구 방향 전환과도 정확히 맞닿아 있다.

요 약

세부 과제	시기	실행 결과	산출물
'교사-AI협업'을 위한 AI·디지털 교육 환경 조성	3~5월	○ '교사-AI협업'을 위한 AI 채점 프로그램(클리포) 선정 및 계약 ○ 전 교사 업무용 PC에 AI프로그램 구동 환경 조성 ○ 학생용 태블릿 PC와 전교실 무선 인터넷 환경 점검	AI프로그램 선정 협의록 및 계약서

【표 15】 세부 과제 1-다 요약

라. 교원의 평가 전문성 및 역량 신장을 위한 집중 연수 및 컨설팅 운영

계획 단계에서 설정한 연수·컨설팅 체계에 따라 총 6회의 연수를 실시하였다. 연구 초기에는 연구학교 방향과 AI 활용·채점 도구 이해에 초점을 두었고, 연구를 진행하면서 높아진 교사들의 성취평가제와 루브릭에 대한 관심을 반영하여 10월 1~2일 성취평가제·루브릭 개발 등 평가의 본질을 주제로 한 심화 연수를 추가 운영하였다.

아울러 계획 단계 컨설팅(2월), 실천단계 컨설팅 및 중간평가(7월)를 거쳤으며, 연수 내용의 중심축은 연구 초반의 '**AI 활용·클리포 활용법**'에서 점차 '**성취평가제·루브릭 설계·평가의 타당성**'으로 이동하였다. 10월에 진행된 성취평가제 심화 연수는 이러한 방향 전환을 교사 공동의 평가 전문성으로 정착시키기 위한 후속 조치라는 의미를 갖는다.

단계	시기	대상	강사	연수 내용	비고
1차	2/23(월) 9:00~10:00	교원 14명	조○○ (내부강사)	연구학교 운영 중점 과제 이해	대면 연수
2차	4/2(목) 9:00~10:00	학생 66명 학부모 16명 교원 14명	조○○ (내부강사)	연구학교 운영 중점 과제 안내	학교 공개의 날 연계
3차	5/11(월) 15:30~16:30	교원 7명	조○○ (내부강사)	학생평가 역량강화	대면 연수
4차	6/12(금) 15:30~17:00	교원 12명	엄○○ 우신고등학교 교사 (외부강사)	학생평가 역량강화 클리포 활용 방법	대면 연수
5차	10/1(목) 17:00~18:00	교원 10명	박○○ 구미 상모고등학교 수석교사 (외부강사)	학생의 배움과 성장을 돕는 수업과 평가의 방향 이해 (성취평가제 심화)	비대면 연수
6차	10/2(금) 15:00~16:30	교원 10명			대면 연수

【표 16】 연수 운영 결과

요 약

세부 과제	시기	실행 결과	산출물
교원의 평가 전문성 및 역량 신장을 위한 집중 연수 및 컨설팅 운영	연중	○ 교사의 평가 역량 강화를 위한 연수 실시(6회) ○ 연구학교 운영 컨설팅 실시(계획/실천단계)	연수 계획서 및 보고서

【표 17】 세부 과제 1-라 요약

과제2 ‘이음 교육과정’ 기반 미래형 학생 평가 ‘이음-평가 모델’ 구축

2022 개정 교육과정과 ‘이음 교육과정’의 철학을 담고, 성취평가제의 목표를 실현하기 위한 평가 모델(이음-평가)을 구축하며, 이를 토대로 ‘교실-삶 이음’의 서·논술형 평가 문항과 ‘이음형 표준 루브릭’을 개발하였다.

가. ‘이음-평가 모델’ 실행 로드맵 수립 및 적용

본교의 이음 교육과정을 바탕으로 다양한 학생 평가 모델을 수용하여 교육과정-수업-평가-피드백을 하나로 잇는 ‘이음-평가 모델’ 실행 로드맵을 수립하였다.

□ 이음-평가 모델의 목표

세부 목표	내 용
E(Education)	‘이음 교육과정’을 기반으로, 교육과정-수업-평가-피드백의 유기적 연계를 실현함.
U(Understanding)	학생의 단순 지식 암기가 아닌, 핵심 개념의 ‘깊이 있는 이해’와 지속적인 성장을 돕는 과정중심평가를 지향함.
M(Meaningful AI)	‘의미 있는 AI’를 활용하여 교사의 평가(채점) 부담을 경감시키고, 교사는 맞춤형 학생 피드백 등의 평가의 본질에 집중함.

【표 18】 이음-평가 모델 목표

□ 이음-평가 모델의 교육과정-수업-평가 실행 로드맵

1단계	2단계	3단계	4단계
교육과정 분석	수업 및 평가 설계하기	수업 및 평가 실시하기	피드백 및 기록하기
성취 기준 분석 핵심 아이디어 도출 탐구 질문 만들기	탐구 질문을 해결하기 위한 수업 및 평가 설계하기	탐구 질문을 해결하기 위한 교수·학습 및 탐구 질문 해결 여부를 판단하기 위한 평가 실시	평가를 통해 학습자의 정확한 성취 수준을 파악하고, 성장을 위한 맞춤형 피드백 제공

【표 19】 이음-평가 모델 로드맵

계획서에 제시된 이음-평가 모델의 목표는 실제 운영의 기본 틀로 그대로 유지되었다. 다만 실행 로드맵의 4단계 가운데, 1학기에는 특히 2단계(탐구 질문 중심 문항 설계)에 연구 역량이 집중되었고, 4단계(피드백)는 시간 부족으로 충분히 실행되지 못한 채 2학기 보완 과제로 이월되었다.

요 약

세부 과제	시기	실행 결과	산출물
‘이음-평가 모델’ 실행 로드맵 수립 및 적용	3~4월	○ ‘이음-평가 모델’ 실행 로드맵 확립 ○ ‘이음-평가 모델’ 자체 연수 및 공유	‘이음-평가 모델’ 실행 로드맵

【표 20】 세부 과제 2-가 요약

나. ‘교실-삶 이음’ 기반의 서·논술형 평가 문항 개발

2022 개정 교육과정의 교과별 성취기준·핵심 아이디어를 토대로 학생의 ‘교실 안 배움’과 ‘실제 삶’을 잇는 탐구질문을 도출하고 이를 중심으로 서·논술형 평가 문항을 개발하였다.

1학기 역사과에서는 성취기준 ‘[9역03-01] 수·당 시기 동아시아 국제 질서의 특징을 이해하고, 동아시아 문화를 탐구한다.’를 다루며 오늘날 동아시아 국제질서와 비교·분석하는 교실-삶 이음 탐구질문으로 확장하였다. 2학기 역사과 성취기준 ‘[9역05-02] 서양의 산업화와 제국주의 정책을 이해하고, 사회와 생태환경에 미친 영향을 분석한다.’에서는 ‘산업화와 제국주의의 경험은 오늘날 사회와 생태환경의 문제를 이해하고 더 나은 선택을 하는 데 어떤 교훈을 줄 수 있을까?’를 큰 탐구질문으로 설정하고, 역사적 이해 → 영향 분석 → 오늘날 문제와 연결 → 토론 논제 생성 → 주장·논거·근거 구성 → 최종 입론의 흐름으로 문항을 재설계하였다.

이 과정에서 인문교과(국어·사회·영어)는 기존에도 서·논술형 평가 경험이 있어 평가 유형 자체에 대한 부담보다는 성취기준 분석부터 평가요소 도출, 탐구질문·비계 질문 설계, 루브릭 연결에 이르는 문항 개발의 체계성을 높이는 방향으로 변화가 나타났다. 반면 수학·과학 교과는 서·논술형 평가 자체의 적용 경험이 상대적으로 적어 문항 설계에 더 많은 시간이 소요되었다.

계획서에 제시한 교과별 탐구질문 사례는 2학기 문항 고도화 과정의 출발점으로 활용하였다. 실제 운영에서는 교과별 형식을 동일하게 맞추기보다, ‘성취기준 분석 → 평가요소 도출 → 교실-삶 이음 탐구질문 → 단계별 비계 질문 → 핵심 평가 질문 → 루브릭’의 공통 절차를 공유하고 각 교과의 지식 구조와 학생 특성에 맞게 구체적 문항 형식을 달리하는 방향으로 정리하였다. 9월 22일 공동 협의회에서는 이 원리에 따라 교과별 2학기 문항을 상호 검토하였다.

문항 개발 과정에서 AI는 성취기준 분석, 평가요소 도출, 탐구질문·문항 아이디어 생성 단계에서 초안을 제공하는 역할을 하였으며, 교사는 AI가 생성한 결과를 그대로 사용하지 않고 수업 맥락과 학생 특성에 맞게 수정·정교화한 뒤 실제 평가에 적용하였다. 이 경험을 통해 AI는 교사의 문항 개발을 대신하는 주체가 아니라, 아이디어를 확장하고 초안을 제공하며 교사의 판단을 자극하는 협업 도구로 규정하는 것이 적절하다는 인식에 이르렀다.

⊙ 교실-삶 이음 탐구 질문을 활용한 서·논술형 평가 문항 사례

교과	성취기준	교실- 삶 이음 탐구질문	서·논술형 평가 문항
국어	[9국03-03] 주장을 뒷받침할 수 있는 타당	우리 학교생활에서 개선하고 싶은 문제를 해결하기 위해 어떤 주장과	학교생활에서 개선이 필요하다고 생각하는 문제 한 가지를 선정하고,

	한 근거를 들고 적절한 표현을 사용하여 주장하는 글을 쓴다.	근거를 제시해야 다른 사람을 설득할 수 있을까?	자신의 주장을 분명히 제시하시오. 주장을 뒷받침할 수 있는 타당한 이유와 근거를 제시하고, 적절한 표현을 사용하여 건의문을 작성하시오.
수학	[9수04-02] 자료를 줄기와 잎 그림, 도수분포표, 히스토그램, 도수분포다각형으로 나타내고 해석할 수 있다.	우리 학교생활과 관련된 자료를 어떻게 나타내고 해석하면 자료의 분포와 특징을 효과적으로 파악할 수 있을까?	우리 학교 학생들의 생활과 관련된 자료(예: 하루 스마트폰 사용 시간, 수면 시간, 운동 시간 등)를 줄기와 잎 그림, 도수분포표, 히스토그램, 도수분포다각형 중 적절한 방법으로 나타내시오. 그 표현 방법을 선택한 이유와 자료의 분포에서 알 수 있는 특징을 설명하고, 분석 결과를 학교생활에 어떻게 활용할 수 있을지 제안하시오.
과학	[9과08-03] 물질의 특성을 이용하여 혼합물이 분리되는 원리를 이해하고, 이를 이용한 사례를 주변에서 찾을 수 있다.	생활 속 혼합물에서 필요한 물질을 효과적으로 분리하려면 어떤 물질의 성질을 이용해야 할까?	제시된 혼합물을 분리하기 위한 방법을 제안하고 그 과정에서 이용한 물질의 특성을 설명하시오. 또한 같은 원리가 활용되는 생활 속 사례를 찾아 그 원리와 연결하여 설명하시오.
사회(역사)	[9역05-02] 서양의 산업화와 제국주의 정책을 이해하고, 사회와 생태환경에 미친 영향을 분석한다.	산업화와 제국주의의 경험은 오늘날 사회와 생태환경의 문제를 이해하고 더 나은 선택을 하는 데 어떤 교훈을 줄 수 있을까?	산업화가 제국주의 정책의 확대에 미친 영향을 설명하고, 산업화와 제국주의가 사회와 생태환경에 미친 영향을 오늘날의 문제와 연결하여 분석하시오. 이를 바탕으로 토론 논제를 만들고 자신의 주장과 근거가 드러나는 토론 입론을 작성하시오
영어	[9영02-04] 친숙한 주제에 관해 경험이나 계획을 설명한다. [9영02-06] 친숙한 주제에 관해 자신의 의견을 주장한다. [9영02-10] 적절한 전략을 활용하여 상황이나 목적에 맞게 말하거나 쓴다.	친구나 가족과 의견이 다를 때 갈등을 줄이고 서로 이해하기 위해 어떻게 소통할 수 있을까?	자신이 실제로 겪은 의견 차이나 갈등 상황을 제시하고, 자신의 의견과 이유를 밝힌 뒤 학습한 소통 전략을 활용하여 갈등을 해결할 수 있는 방법을 영어로 작성하시오.

【표 21】 교실-삶 이음 서·논술형 평가 문항 개발 사례

요 약

세부 과제	시기	실행 결과	산출물
'교실-삶 이음' 기반의 서·논술형 평가 문항 개발	연중	○ 교과별 탐구질문, 교실-삶 이음 탐구질문 개발 ○ 서·논술형 평가 문제 은행 구축(워크스페이스 활용)	교과별 서·논술형 평가 문항 사례

【표 22】 세부 과제 2-나 요약

다. 학생의 성장을 지원하는 '이음형 표준 루브릭' 개발

루브릭 개발은 1학기와 2학기 사이에 뚜렷한 구조적 변화를 거쳤다. 1학기에는 교사-AI 채점의 일치도를 높이는 것이 우선 과제였기 때문에, 하나의 평가요소를 다시 정량 영역과 정성 영역으로 분리하는 방식으로 루브릭을 설계하였다. 정량 영역은 AI가 상대적으로 객관적으로 판단할 수 있는 사실적 요소의 개수 등을 기준으로 제시하고, 정성 영역은 학생의 답변이 교과의 개념·원리와 평가 맥락에 비추어 얼마나 타당하고 적절하게 설명·분석되었는지를 판단할 수 있도록 서술형으로 진술하였다.

⦿ 1학기 이음형 표준 루브릭 사례

❍ 역사

세부 평가 기준					
평가 요소	채점 기준				
	정량		배점	정성	배점
수·당 시기 동아시아 문화의 공통적 특징 분석하기 [탐구질문 해결을 위한 핵심개념 정리하기]	A	수·당 시기 동아시아 문화의 공통적 특징을 4가지 도출하였다.	10	주어진 자료를 토대로 공통적 특징에 대한 핵심개념을 설명하였다.	20
	B	수·당 시기 동아시아 문화의 공통적 특징을 3가지 도출하였다.	8	주어진 자료를 토대로 공통적 특징을 설명하였다.	18
	C	수·당 시기 동아시아 문화의 공통적 특징을 2가지 도출하였다.	6	공통적 특징을 서술하였으나 주어진 자료와의 관련성이 낮다.	16
	D	수·당 시기 동아시아 문화의 공통적 특징을 1가지 도출하였다.	4	공통적 특징을 서술하였으나 주어진 자료와의 관련성이 없다.	14
	E	수·당 시기 동아시아 문화 특징을 확인하였다.	2	공통적 특징을 서술하지 못하였다.	12
수·당 시기 동아시아 문화의 공통적 특징이 나타난 배경 추론하기 [탐구질문 답안작성하기]	A	수·당 시기 동아시아 문화의 공통적 특징이 나타난 배경을 4개 국가의 사례를 근거로 서술하였다.	10	공통적 특징이 나타난 배경을 수·당을 중심으로 한 동아시아의 국제질서 속에서 이해하고 서술하였다.	24
	B	수·당 시기 동아시아 문화의 공통적 특징이 나타난 배경을 3개 국가의 사례를 근거로 서술하였다.	8	공통적 특징이 나타난 배경을 동아시아 국가들 간의 관계 속에서 이해하고 서술하였다.	22
	C	수·당 시기 동아시아 문화의 공통적 특징이 나타난 배경을 2개 국가의 사례를 근거로 서술하였다.	6	공통적 특징이 나타난 배경을 동아시아 국가들의 교류와 관련지어 파악하였다.	20
	D	수·당 시기 동아시아 문화의 공통적 특징이 나타난 배경을 1개 국가의 사례를 근거로 서술하였다.	4	공통적 특징이 나타난 배경을 동아시아 국가들과 관련지어 파악하였다.	18
	E	수·당 시기 동아시아 문화의 공통적 특징이 나타난 배경을 사례 없이 서술하였다.	2	공통적 특징이 나타난 배경을 서술하였으나 역사적 맥락에 맞지 않는 근거를 제시하였다.	16
수·당 시기 동아시아 국제질서와 오늘날 동아시아 국제질서 비교·분석하기 [교실-삶 이음	A	수·당 시기 동아시아 국제질서와 오늘날 동아시아 국제질서의 공통점 또는 차이점을 3가지 도출하였다.	10	수·당 시기 동아시아 국제질서와 오늘날 동아시아 국제질서를 비교·분석하여 오늘날 국제 질서를 개선하기 위한 방안을 제시하였다.	26
	B	수·당 시기 동아시아 국제질서와 오늘날 동아시아 국제질서의 공통점 또는 차이점을 2가지 도출하였다.	8	수·당 시기 동아시아 국제질서와 오늘날 동아시아 국제질서를 비교·분석하여 오늘날 국제 질서의 특징을	24

탐구질문 답안작성하기]				설명하였다.	
	C	수·당 시기 동아시아 국제질서와 오늘날 동아시아 국제질서 공통점 또는 차이점을 1가지 도출하였다.	6	수·당 시기 동아시아 국제질서와 오늘날 동아시아 국제질서를 비교·분석하여 오늘날 국제 질서를 설명하였다.	22
	D	수·당 시기 동아시아 국제질서와 오늘날 동아시아 국제질서의 주요 특징을 2개 이상 나열하였다.	4	수·당 시기 동아시아 국제질서와 오늘날 동아시아 국제질서를 비교하였다.	20
	E	수·당 시기 동아시아 국제질서와 오늘날 동아시아 국제질서의 사례를 1가지 이하 제시하였다.	2	수·당 시기 동아시아 국제질서와 오늘날 동아시아 국제질서의 사례를 조사하였다.	18
기본점수		**52**			
미제출 (자발적미참여학생, 백지활동지제출자 포함)		**40**			
장기 질병 결석자		**30**			
미인정 장기 결석자		**20**			

【표 23】 역사과 이음형 표준 루브릭

그러나 모든 평가요소를 정량·정성으로 이중 분리하는 작업은 교사에게 상당한 시간과 노력을 요구했고, 정량과 정성의 경계 역시 실제 채점에서 명확하지 않았다. 2학기에는 평가요소의 성격과 성취기준이 요구하는 사고 수준을 먼저 판단한 뒤 하나의 통합된 기대수행으로 진술하는 방향으로 개선하였다. 특히 단계별 질문을 설계하는 과정에서 '논거 2개면 A, 1개면 B' 처럼 개수 중심으로 성취수준을 가르는 방식이 학생의 실제 분석 수준을 충분히 드러내지 못한다는 점을 다시 확인하여, 주장-논거-근거의 연결성과 역사적 타당성, 사회·생태환경에 대한 분석의 질을 중심으로 루브릭을 정교화하였다.

⦿ 2학기 이음형 표준 루브릭(통합형) 사례

❍ 역사

평가요소	기대수행		배점
산업화와 제국주의 정책 이해하기 [40점] [지식·이해]	A	서양의 산업화로 나타난 변화와 새로운 경제적 필요를 바탕으로 제국주의 정책이 확대된 과정을 역사적 인과관계가 드러나도록 구체적으로 설명함.	40
	B	서양의 산업화와 제국주의 정책의 관계를 이해하고, 두 현상의 인과관계를 비교적 명확하게 설명함.	35
	C	서양의 산업화와 제국주의 정책이 서로 관련되어 있음을 이해하고, 그 관계를 기본적인 수준에서 설명함.	30
	D	산업화와 제국주의 정책에 관한 주요 내용을 제시하나, 두 현상의 관계에 대한 설명이 충분하지 않음.	25
	E	산업화 또는 제국주의 정책과 관련된 내용을 일부 제시하나, 두 현상의 관계를 설명하는 데 어려움이 있음.	20
산업화와 제국주의를 주제로 논제	A	산업화와 제국주의가 사회 또는 생태환경에 미친 영향을 바탕으로, 서로 다른 입장에서 논의할 수 있는 명확하고 의미 있는 토론 논제를 만듦.	20

만들기 [20점] [과정・기능]	B	산업화와 제국주의가 사회 또는 생태환경에 미친 영향과 관련하여 찬반 또는 다양한 관점의 논의가 가능한 토론 논제를 만듦.	18
	C	산업화와 제국주의의 영향과 관련된 논제를 만들었으나, 주제와의 연관성이나 토론 가능성이 일부 부족함.	16
	D	산업화 또는 제국주의와 관련된 주제를 제시하였으나, 토론 논제로서의 쟁점이 충분히 드러나지 않음.	14
	E	산업화 또는 제국주의와 관련된 생각이나 주제를 제시하나, 토론할 수 있는 논제의 형태로 구성하는 데 어려움이 있음.	12
산업화와 제국주의가 사회와 생태환경에 미친 영향 분석하기 [40점] [과정・기능]	A	자신의 입장을 명확하게 제시하고, 타당한 논거와 역사적 근거를 유기적으로 연결하여 산업화와 제국주의가 사회・생태환경에 미친 영향을 분석하며, 이를 오늘날의 문제와 연결하여 판단함.	40
	B	자신의 입장과 적절한 논거・근거를 제시하여 산업화와 제국주의가 사회・생태환경에 미친 영향을 체계적으로 설명함.	35
	C	자신의 입장과 논거・근거를 제시하고 관련 영향을 설명하나, 논거와 근거의 연결 또는 영향에 대한 분석이 일부 부족함.	30
	D	자신의 입장을 제시하나, 논거・근거와의 연결이 약하고 사회・생태환경에 미친 영향에 대한 분석이 충분하지 않음.	25
	E	산업화와 제국주의의 영향에 관한 자신의 생각을 일부 제시하나, 이를 논거와 근거를 활용하여 분석하는 데 어려움이 있음.	20

기본점수	52점
미제출 (자발적미참여학생, 백지활동지제출자 포함)	40점
장기 질병 결석자	30점
미인정 장기 결석자	20점

【표 24】 역사과 이음형 표준 루브릭(통합형)

2학기 역사과 이음형 표준 루브릭(통합형)은 세 개의 핵심 평가 질문(산업화-제국주의 인과관계 40점 / 토론 논제 20점 / 최종 입론 40점)을 루브릭으로 평가하도록 재구성하였다. 논거・근거의 개수는 작성 안내로 활용하되, 성취수준은 주장・논거・근거의 연결성, 역사적 타당성, 분석의 질을 중심으로 종합 판단한다.

이 변화는 '표준화해야 할 것은 특정 AI의 사용법이나 모든 교과가 동일하게 쓰는 루브릭 양식이 아니라, 학생의 성취를 제대로 드러내기 위한 평가 설계의 원리와 절차'라는 인식이 실제 문항・루브릭 설계를 통해 구체화된 사례이다. 2학기 통합형 루브릭은 지식・이해, 과정・기능, 가치・태도의 성격을 참고하되 실제 성취기준이 요구하는 수행에 맞추어 평가요소를 도출하고, 단계별 비계 질문은 학습 지원과 사고 구조화를 위해, 핵심 평가 질문은 성취 판단을 위해 기능을 분리하였다. AI가 생성한 루브릭 초안은 수업 맥락・학생 특성・교과 성취기준을 충분히 반영하기 어려운 경우가 많아 최종적으로 '무엇을 어떤 기준으로 평가할 것인지'는 교과 전문가인 교사가 중심이 되어야 한다는 인식도 강화되었다.

아울러 채점 원자료 분석 과정에서 채점기준이 상세할수록 AI가 더 안정적으로 판단하는 경향이 확인된 반면, 학생에게 사전 공개되는 루브릭을 지나치게 상세하게

작성할 경우 사실상 답안의 일부를 미리 알려주는 결과가 될 수 있다는 딜레마도 함께 확인되었다. 이에 학생에게는 평가요소와 기대수행을 알 수 있는 공개용 기준을, 실제 채점의 일관성을 위한 상세기준은 교사용으로 별도 관리하는 방식의 가능성을 검토하고 있다. 다만 이는 학교가 단독으로 결정하기보다 교육청과의 협의가 필요한 정책적 쟁점으로 판단하여, 교육청 컨설팅 과정에서 함께 논의할 계획이다.

요 약

세부 과제	시기	실행 결과	산출물
학생의 성장을 지원하는 '이음형 표준 루브릭' 개발	연중	○ '이음형 표준 루브릭' 개발 및 적용 -1학기 정량·정성 분리형 루브릭 적용 후 한계 확인→2학기 통합형 루브릭으로 구조 개선	교과별 '이음형 표준 루브릭'

【표 25】 세부 과제 2-다 요약

라. '이음-평가 모델' 현장 적용 및 수업-평가-피드백 사례 축적

'교실-삶 이음' 평가가 궁극적으로 지향하는 것은 학생이 교과에서 배운 지식을 세상을 이해하고 필요하다면 변화시키는 데 사용하도록 돕는 것이다. 학교에서 배운 지식이 학생의 머릿속에 독립적으로 저장되는 데 그친다면 살아 있는 지식이라 보기 어렵고, 기존 지식·경험과 연결되어 새롭게 구성·확장되면서 판단과 실천의 도구가 될 때 비로소 살아 있는 지식이 된다는 것이 본교가 공유한 문항 설계 철학이다. 다만 모든 문항이 '세상을 변화시키는 단계'까지 나아가야 하는 것은 아니며, 일상 적용 수준에서 충분한 문항, 현상의 새로운 이해·해석까지 나아가는 문항, 판단·대안 제시·실천까지 확장되는 문항을 학기·학년·교과 전체 차원에서 균형 있게 설계하는 방향성을 중시하였다. 또한 문항에 편의점, 스마트폰 등 생활 소재가 등장한다고 해서 곧 교실-삶 이음 평가가 되는 것은 아니며, 핵심은 교과에서 학습한 개념과 지식이 새로운 상황이나 삶의 맥락을 해석·판단하는 도구로 실제 사용되는지에 있다는 점을 공동 협의를 통해 거듭 확인하였다.

1학기 수행평가는 교과별 형식에 차이가 있었으나, 대체로 큰 탐구 과제와 여러 답안작성 조건을 제시하고 학생이 이를 하나의 완성된 서술 또는 복합 수행으로 조직하도록 요구하였다. 대표 학생 답안을 검토한 결과, 상위권 학생들은 대체로 문항에서 요구한 조건을 확인하고 핵심 개념과 근거, 실생활과의 연결 등을 포함하여 비교적 충실한 답안을 작성하였다. 반면 중·하위권 학생들은 무엇을 어떻게 서술해야 하는지 파악하는 데 어려움을 보였으며, 여러 답안작성 조건을 동시에 충족하지 못하거나 자신의 생각을 문장으로 조직하는 과정에서 어려움을 겪는 사례가 나타났다. 특히 일부 학생은 첫 문장을 시작하는 것 자체에 부담을 느끼거나, 답안을 작성하더라도 요구된 조건의 일부만 반영하는 모습을 보였다. 따라서 1학기 문항의 한계를 단순히 '학생들이 장문을 쓰지 못했다'는 문제로 해석하기보다, 하나의 복합 과제 안에 여러 사고 과정과 작성 조건이 동시에 요구되면서 학생의 교과 성취뿐 아니라 글쓰기

능력과 조건 해석 능력의 차이까지 크게 드러났고, 이것이 특히 중·하위권 학생의 수행을 제약하는 진입 장벽으로 작용한 것으로 해석하였다.

이러한 결과를 반영하여 5차 협의회(7/21)에서는 2학기 서·논술형 평가의 개선 방향으로 '단계별 비계 질문'의 도입을 확정하였다. 1학기 평가에서 상위권 학생들은 대체로 여러 답안작성 조건을 스스로 해석하고 자신의 생각을 하나의 완성된 답안으로 조직할 수 있었으나, 중·하위권 학생들은 교과 내용을 알고 있더라도 여러 조건을 동시에 확인하고 주장·이유·근거 등을 스스로 조직하여 글로 표현하는 과정에서 어려움을 겪는 경우가 많았다. 이에 평가에서 요구하는 사고 수준 자체를 낮추기보다, 학생이 핵심 수행에 도달하기까지의 사고 과정을 작은 단계로 나누어 안내함으로써 교과 성취와 직접 관련되지 않은 글쓰기 및 조건 해석의 부담을 줄이고자 하였다.

2학기 평가도구를 구체화하는 과정에서는 여기에서 한 단계 더 나아가, '단계별 질문을 제시한다는 것이 곧 모든 단계의 답안을 각각 채점한다는 의미는 아니다'라는 원칙을 설정하였다. 모든 단계별 질문에 점수를 부여할 경우 학생은 각 질문을 또 하나의 평가과제로 인식하게 되고, 교사 역시 다수의 짧은 답안을 일일이 채점해야 하므로 오히려 평가 부담이 증가할 수 있기 때문이다. 이에 단계별 질문 가운데 앞부분은 배경지식을 활성화하고 개념 간 관계를 파악하며 주장·논거·근거를 구성하도록 돕는 무점수 비계 질문으로 활용하고, 성취기준과 평가요소에 직접 연결되어 학생의 최종적인 성취를 드러내는 핵심 평가 질문의 답안만을 점수화하는 방식으로 평가 구조를 개선하였다. 즉, 수업 과정에서는 비계 질문과 교사의 피드백을 통해 학생의 사고 형성을 지원하고, 이후 핵심 수행에서 성취수준을 판단함으로써 모든 학습 활동을 점수화하기보다 학습 과정의 지원과 성취 판단을 유기적으로 연결하는 과정중심평가를 구현하고자 하였다.

단계별 비계 질문은 1학기 말 형성평가에서 우선 시범 적용하였다. 이 과정에서 학생들이 이전보다 질문의 의미와 답안작성 조건을 세밀하게 확인하려는 모습이 관찰되었으며, 특히 중·상위권 학생들은 순차적으로 제시된 질문을 통해 주장과 근거 등 논리적 글쓰기의 구조를 보다 명확하게 파악하는 모습을 보였다. 다만 이는 성적에 반영되는 본 평가가 아닌 형성평가에서 나타난 예비적 관찰이므로, 이를 단계별 비계 질문의 효과로 단정하기보다는 2학기 성적 반영 평가를 통해 추가로 확인할 필요가 있다고 판단하였다.

이를 토대로 2학기 역사과 [9역05-02] '산업화와 제국주의' 평가에서는 '비계 질문 → 핵심 평가 질문'이 반복되는 구조로 평가도구를 재설계하였다. 먼저 산업화와 제국주의의 인과관계를 이해하도록 돕는 비계 질문을 제시한 뒤 핵심 평가 질문1(지식·이해, 40점)에서 그 관계를 설명하도록 하고, 사회·생태환경에 미친 영향을 탐색하는 비계 질문을 거쳐 핵심 평가 질문 2(토론 논제 만들기, 20점)를 수행하도록

구성하였다. 이후 자신의 주장과 논거·근거를 단계적으로 구성하는 비계 질문을 제공한 뒤 이를 종합하여 핵심 평가 질문 3(토론 입론 작성, 40점)에 답하도록 하였다.

이와 같이 2학기 개선안은 1학기의 '활동을 단계화한 평가'에서 학생의 '사고 과정을 단계화한 평가'로 발전하였으며, 동시에 비계 질문과 실제 평가 질문을 구분함으로써 학생의 학습을 지원하면서도 평가 부담은 최소화하는 방향으로 정교화하였다.

⊙ 단계형 비계 질문 사례

교과	교실-삶 이음 탐구질문	단계별 비계 질문(성적 미반영)	핵심 평가 질문(성적 반영)
국어	내가 잘 알고 있거나 나에게 의미 있는 대상을 다른 사람이 쉽게 이해하도록 설명하려면 어떻게 글을 써야 할까?	① 내가 설명하고 싶은 대상이나 활동은 무엇인가? ② 이 글을 읽을 사람은 이 대상에 대해 무엇을 알고 있고, 무엇을 궁금해할까? ③ 독자가 꼭 알아야 할 핵심 정보 3가지를 골라보자. ④ 내가 선정한 내용을 설명하기 위해 정의·예시·비교·분류·인과 등의 설명 방법 중 어떤 방법을 활용하면 좋을까? ⑤ 그 설명 방법이 해당 내용을 전달하는 데 적절한 이유는 무엇인가? ⑥ 이 대상이나 활동이 나의 실제 생활과 어떤 관련이 있는가? ⑦ 독자가 내 글을 읽은 뒤 가장 잘 이해했으면 하는 점은 무엇인가? ⑧ 작성한 글에서 독자가 이해하기 어려울 만한 부분은 없는지 다시 확인해 보자.	핵심 질문 1 설명할 대상과 독자를 고려하여 글에서 다룰 핵심 내용을 선정하고, 어떤 순서로 설명할지 글의 개요를 작성하시오. 핵심 질문 2 선정한 내용에 적절한 설명 방법을 활용하여 독자가 대상을 쉽게 이해할 수 있도록 한 문단을 작성하시오. 핵심 질문 3 앞에서 구성한 내용을 바탕으로 대상의 특징과 자신의 삶과의 관련성이 잘 드러나는 설명 글을 완성하시오.
수학	제한된 조건 속에서 더 합리적인 선택을 하기 위해 부등식을 어떻게 활용할 수 있을까? 예: 학교 체험활동의 이동 계획에서 제시된 비용·탄소배출량 등의 조건을 만족하는 인원 또는 이동 방법 결정	① 문제에서 변하는 값을 무엇으로 정하면 좋을까? ② 주어진 자료에서 반드시 지켜야 하는 조건은 무엇인가? ③ 각 조건을 식으로 나타내면 어떻게 표현할 수 있을까? ④ 구한 부등식의 해는 실제 상황에서 무엇을 의미하는가? ⑤ 계산 결과 중 실제 상황에서는 사용할 수 없는 값이 있는가? 그 이유는 무엇인가? ⑥ 두 가지 선택 방법을 비교하면 각각 어떤 장점과 한계가 있는가? ⑦ 수학적 계산 결과 외에 실제	핵심 질문 1 제시된 생활 상황에서 해결해야 할 값을 미지수로 정하고, 조건에 맞는 일차부등식을 세워 해결하시오. 핵심 질문 2 부등식의 해를 실제 상황에 맞게 해석하고, 조건을 만족하는 가장 적절한 선택을 제안하시오. 핵심 질문 3 계산 결과를 근거로 자신의 선택을 설명하고, 일차부등식이 실제 생활의 의사결정에 어떻게

		선택에서 함께 고려해야 할 조건은 무엇인가?	활용될 수 있는지 서술하시오.
과학	생활 속 혼합물에서 필요한 물질을 분리하려면 어떤 물질의 성질을 이용해야 할까?	① 소금과 모래는 물에 넣었을 때 각각 어떻게 되는가? ② 두 물질의 어떤 성질이 서로 다른가? ③ 물에 녹지 않은 물질과 녹아 있는 물질을 분리하려면 어떤 방법을 사용할 수 있을까? ④ 거름 장치를 사용한 뒤 얻어지는 물질은 각각 어디에 존재하는가? ⑤ 소금물에서 다시 소금을 얻으려면 어떤 성질을 이용해야 하는가? ⑥ 분리 순서를 바꾸면 같은 결과를 얻을 수 있을까? ⑦ 우리 생활이나 산업에서 혼합물을 분리하는 사례에는 무엇이 있는가? ⑧ 그 사례에서는 어떤 성질의 차이를 이용하고 있는가?	핵심 질문 1 소금과 모래가 섞여 있을 때 두 물질을 각각 분리하기 위한 과정을 순서대로 제시하고, 각 과정에서 이용한 물질의 성질을 설명하시오. 핵심 질문 2 제시한 분리 방법이 적절한 이유를 용해도, 끓는점 등 관련된 물질의 성질을 이용하여 설명하시오. 핵심 질문 3 생활 속 혼합물 분리 사례 하나를 찾아 교실에서 학습한 분리 원리와 연결하여 설명하고, 해당 분리 방법이 필요한 이유를 제시하시오.
사회(역사)	산업화와 제국주의의 경험은 오늘날 사회와 생태환경의 문제를 이해하고 더 나은 선택을 하는 데 어떤 교훈을 줄 수 있을까?	① 산업화로 유럽의 생산과 경제에는 어떤 변화가 나타났는가? ② 산업화 이후 유럽이 이전보다 더 많이 필요로 하게 된 것은 무엇인가? ③ 이러한 변화는 유럽 국가의 해외 진출과 어떤 관계가 있었을까? ④ 산업화와 제국주의는 당시 사람들의 삶과 사회에 어떤 영향을 주었는가? ⑤ 자연환경이나 자원 이용에는 어떤 영향을 주었는가? ⑥ 오늘날에도 이와 비슷한 문제가 나타나는 사례가 있는가? ⑦ 자신의 입장은 무엇인가? ⑧ 그렇게 생각하는 이유는 무엇인가? ⑨ 그 이유를 뒷받침할 역사적 근거는 무엇인가? ⑩ 이 역사적 경험을 오늘날의 문제와 어떻게 연결할 수 있는가?	핵심 질문 1 산업화가 서양의 제국주의 정책 확대에 어떤 영향을 주었는지 인과관계가 드러나도록 설명하시오. 핵심 질문 2 산업화와 제국주의가 사회 또는 생태환경에 미친 영향을 바탕으로 서로 다른 입장에서 토론할 수 있는 논제를 만드시오. 핵심 질문 3 자신의 주장과 타당한 논거·역사적 근거를 활용하여 토론 입론을 완성하고, 산업화와 제국주의의 경험이 오늘날 우리 사회에 주는 의미를 함께 제시하시오.
영어	친구나 가족과 의견이 다를 때 갈등을 줄이고 서로 이해하기 위해 어떤 방법으로 소통할 수 있을까?	① 의견이 다른 사람과 대화할 때 사용할 수 있는 표현이나 소통 전략에는 무엇이 있는가? ② 각 표현이나 전략은 어떤 상황에서 사용할 수 있는가? ③ 내가 실제로 사용할 수 있을 것 같은 전략을 골라보자.	핵심 질문 1 의견 차이가 있는 상황에서 사용할 수 있는 적절한 영어 표현과 소통 전략을 선택하고, 그 의미와 활용 방법을 영어로 설명하시오. 핵심 질문 2 효과적인 의사소통

		④ 효과적인 소통을 위해 가장 중요하다고 생각하는 방법은 무엇인가? ⑤ 그렇게 생각한 이유는 무엇인가? ⑥ 그 이유를 뒷받침할 수 있는 구체적인 상황이나 예를 생각해 보자. ⑦ 친구·가족 등과 의견이 달랐던 경험을 하나 떠올려보자. ⑧ 당시 나는 어떻게 행동했으며 어떤 결과가 나타났는가? ⑨ 앞에서 학습한 소통 전략 중 하나를 사용했다면 어떻게 행동할 수 있었을까? ⑩ 그 전략을 사용하면 결과가 어떻게 달라질 수 있을까?	을 위해 중요하다고 생각하는 방법에 대한 자신의 의견과 이유를 영어로 작성하시오. 핵심 질문 3 자신의 실제 경험 한 가지를 제시하고, 학습한 소통 전략을 그 상황에 어떻게 적용할 수 있는지 영어로 구체적으로 작성하시오.

【표 26】단계형 비계질문 사례

요 약

세부 과제	시기	실행 결과	산출물
‘이음-평가 모델’ 현장 적용 및 수업-평가-피드백 사례 축적	연중	○ ‘이음-평가 모델’ 적용 ○ 수업-평가-피드백 사례 축적(워크스페이스 활용) ○ 축적된 사례를 통한 모델 고도화(공동 협의회)	공동 협의록

【표 27】 세부 과제 2-라 요약

과제3 ‘교사-AI 협업’ 평가 체제 구축 및 검증

‘이음-평가 모델’에 AI를 결합하여 평가도구 개발부터 채점·분석·피드백에 이르는 과정에서 AI가 교사의 전문적 판단을 지원하는 ‘교사-AI 협업’ 평가 체제를 구축하고 그 가능성과 한계를 검증하였다. 연구 초기에는 AI를 활용한 서·논술형 채점의 자동화와 교사-AI 간 채점 일치도 향상에 상대적으로 큰 비중을 두었으나, 실제 평가도구를 개발하고 학생 답안을 채점하는 과정에서 AI 채점의 신뢰성은 AI 자체의 성능뿐 아니라 문항과 루브릭이 얼마나 타당하고 명료하게 설계되어 있는가에 크게 영향을 받는다는 점을 확인하였다.

이에 연구의 초점을 단순한 AI 채점 자동화에서 확장하여, 교사가 성취기준을 분석하고 평가요소를 도출하며 교실-삶 이음 탐구질문·서·논술형 문항·루브릭을 설계하는 과정에서 AI의 도움을 받을 수 있는 협업 체제를 구축하는 방향으로 발전시켰다. 동시에 실제 학생 답안의 채점에서는 AI가 교사를 대신하여 최종 점수를

결정하기보다, 교사의 채점 결과와 비교하여 판단의 근거를 점검하고 문항과 루브릭의 문제점을 발견하는 제2의 채점자이자 검토 도구로 활용하였다. 이를 통해 본 연구에서는 특정 AI 프로그램의 성능을 검증하는 데 그치지 않고, 평가 설계와 채점 과정에서 교사와 AI가 각각 어떤 역할을 담당하는 것이 교육적으로 타당한가를 탐색하고자 하였다.

가. '교사-AI 협업' 평가도구 개발 지원 체제 구축

연구 초기에는 구글 폼을 통해 학생 답안을 수집하고, 스프레드시트에 답안을 자동으로 탑재한 뒤 채점 기준과 연동하여 AI가 채점·분석·피드백까지 제공하는 AI 서·논술형 자동채점 시스템을 개발하는 것을 주요 방향으로 설정하였다. 그러나 자체 시스템을 개발하고 실제 평가에 적용하는 과정에서, 채점 과정의 자동화만으로는 교사-AI 협업 평가의 질을 충분히 높이기 어렵다는 점을 확인하였다. 특히 성취기준과 평가요소의 연결이 불분명하거나 문항의 요구가 모호하고 루브릭이 충분히 정교하지 않은 경우에는 AI의 성능과 관계없이 일관된 채점 결과를 얻기 어려웠다.

이러한 경험을 바탕으로 자체 개발 프로그램의 중심 기능을 'AI가 채점하는 프로그램'에서 'AI가 교사의 평가도구 개발을 지원하는 프로그램'으로 전환하였다. 이에 따라 프로그램은 성취기준 및 성취수준 분석·재구성, 평가요소 도출, 교실-삶 이음 탐구 질문 개발, 서·논술형 평가문항 생성·검토 등 평가 설계의 앞단을 지원하는 방향으로 개발·보완하였다. 이후 단계별 비계 질문의 필요성이 제기되면서 성취기준 분석 → 평가요소 도출 → 교실-삶 이음 탐구질문 → 단계별 비계 질문 및 핵심 평가 질문 → 루브릭으로 이어지는 평가도구 개발 절차를 AI가 지원할 수 있도록 기능과 활용 방향을 구체화하였다.

이 과정에서 자체 개발 프로그램은 교사의 평가 판단을 대신하여 완성된 문항이나 루브릭을 자동으로 결정하는 도구로 활용하지 않았다. AI가 다양한 아이디어와 초안을 제시하면 교사가 교육과정, 실제 수업 내용, 학생의 수준과 특성을 고려하여 이를 선택·수정·보완하는 방식으로 활용하였다. 이를 통해 표준화해야 할 것은 특정 AI 프로그램의 사용 방법이 아니라 성취기준에서 평가요소를 도출하고 이를 문항과 루브릭으로 일관되게 연결하는 평가 설계의 원리와 절차라는 방향을 정립하였다.

한편 학생 답안에 대한 AI 채점의 실제 가능성을 검증하기 위해서는 상용 OCR 기반 채점 시스템인 클리포(Clipo)를 활용하였다. 학생이 종이에 작성한 서·논술형 답안을 스캔하여 클리포에 입력하고 AI가 채점하도록 하는 동시에, 교사는 원본 답안을 독립적으로 채점한 뒤 두 결과를 비교하였다. 클리포가 제시한 점수뿐 아니라 채점 근거와 피드백 내용도 함께 검토함으로써 단순한 총점 일치 여부를 넘어 AI와 교사의 판단이 어느 지점에서 일치하거나 달라지는지, 그 원인이 문항·루브릭·학생 표현·OCR

인식 중 어디에 있는지를 분석하였다.

이를 통해 자체 개발 AI 프로그램은 평가도구 설계 지원, 상용 AI 채점 시스템은 실제 답안 채점 및 교사 판단과의 비교·검증이라는 서로 다른 역할을 담당하게 되었다. 결과적으로 본 연구의 교사-AI 협업 체제는 하나의 AI가 평가 전 과정을 자동화하는 방식이 아니라, 교사가 평가의 목적과 기준을 결정하고 AI가 평가도구 개발과 채점 판단을 단계별로 지원하는 구조로 구체화되었다.

한편 학생의 수행평가 답안과 평가 결과를 AI 시스템에서 처리하는 과정에서는 개인정보 보호와 데이터 보안을 함께 고려하였다. 클리포의 개인정보처리방침 및 보안 안내에 따르면 학생 정보는 서비스 제공에 필요한 범위에서 수집·이용되며, 만 14세 미만 학생의 경우 법정대리인의 동의를 전제로 학생 정보를 등록하도록 하고 있다. 또한 학생 과제물에 포함된 이름·학번 등의 개인정보는 AI 채점 전에 자동으로 비식별 처리되어 생성형 AI에 직접 전달되지 않으며, 개인정보와 평가 데이터는 암호화 저장·전송, 접근권한 관리, 침입차단 및 백업 등의 방식으로 보호된다. 이에 본 연구에서도 AI 채점 시스템 활용 시 채점의 신뢰도뿐 아니라 학생 개인정보와 평가정보를 안전하게 처리할 수 있는지를 중요한 적용 조건으로 함께 고려하였다.

구분	초기 계획(구글 폼 기반 자동화 4단계)	실제 운영 방식(클리포 도입 이후)
1단계	학생이 교사가 제공한 구글 폼에 서·논술형 답안을 작성·제출	학생이 종이에 서·논술형 답안을 작성
2단계	구글 폼 답안이 앱스 스크립트를 통해 교과별 채점용 스프레드시트에 자동 입력	교사가 학생 답안을 스캔하여 이음형 표준 루브릭이 입력된 클리포에 업로드
3단계	채점 기준 시트에 입력된 표준 루브릭과 연동하여 정량·정성 영역을 구분해 AI가 채점	AI가 OCR로 답안을 인식하여 채점함과 동시에 교사가 원본 답안으로 독립 채점(교사-AI 병행·비교 채점)
4단계	AI가 종합 결과 및 피드백 시트에 최종 성취도와 맞춤형 피드백 방안을 산출, 교사가 확인 후 피드백 제공	교사가 AI 채점 근거·점수와 자신의 채점 결과를 비교·검토하여 최종 성취도를 확정하고 피드백을 결정

【표 28】 AI 서·논술형 평가 채점 시스템 초기 계획과 실제 운영 방식 비교

요 약

세부 과제	시기	실행 결과	산출물
'교사-AI 협업' 서·논술형 평가 시스템 개발	연중	○ 서·논술형 채점 프로그램 3단계 기술적 전환 -자체개발→바이브 코딩 웹앱→클리포 도입 ○ AI 교사 활용 실무 연수 실시 ○ 교과별 AI 서·논술형 평가 시스템 고도화	AI 서·논술형 평가 시스템

【표 29】 세부 과제 3-가 요약

나. ‘교사-AI 협업’ 채점 프로세스 확립

본 연구가 추구하는 ‘AI 채점 자동화’는 ‘완전 자동화’가 아닌 ‘교사-AI 협업’ 모델이다. 교수·학습부터 평가, 최종 피드백까지의 업무 흐름과 역할 구분 기준을 명확하게 수립하여 운영하였다.

계획 단계에서는 정량적 요소는 AI, 정성적 요소는 교사가 상대적으로 더 큰 역할을 담당하는 역할 분담형 협업을 상정하였다. 그러나 1학기 실제 운영에서는 정량·정성의 경계를 사전에 고정하기 어려웠고, 짧은 연구기간 안에 역할 분담 모델을 충분히 검증하기도 어려웠다.

이에 이번 연구에서는 교사와 AI가 동일 답안을 각각 독립적으로 채점하고, AI가 제시한 점수·채점 근거·피드백과 교사의 판단을 비교한 뒤 교사가 최종 점수를 확정하는 병행채점 방식을 중심으로 운영하였다. 이러한 경험을 통해 역할 분담의 가능성은 확인하되, 현재 단계에서 AI의 가장 현실적인 역할은 교사의 판단을 재검토하게 하는 제2의 채점자이자 더블 체크 도구라는 데 교사들의 공감대가 형성되었다.

요 약

세부 과제	시기	실행 결과	산출물
‘교사-AI 협업’ 채점 프로세스 확립	연중	○ 교사·AI가 동일 답안을 독립 병행채점하고 점수·근거·피드백을 비교하는 프로세스 정착	채점 결과 및 피드백 방안

【표 30】 세부 과제 3-나 요약

다. 채점 결과 비교 분석을 통한 평가의 신뢰도 및 타당성 검증

1학기 2학년 학생 22명의 수행평가 답안을 대상으로 과학·역사·영어·수학 4개 교과에서 교사와 AI 채점 시스템(클리포)이 각각 독립적으로 채점한 원자료를 비교하였다. 국어과도 연구 전 과정과 교사-AI 비교채점에 참여하였으나, 채점 결과를 전산화하는 과정에서 일부 자료가 누락·소실되어 본 통계 분석에서는 제외하였다. 총 88건의 교과-학생 사례에 대해 고정분할점수 기준으로 최종 성취도를 산출한 결과, 71건에서 교사와 AI의 성취도 분류가 일치하여 전체 일치율은 80.7%로 나타났다. 전체 총점 평균은 교사 85.0점, AI 85.4점으로 집단 수준에서는 거의 유사하였다. 그러나 교사와 AI의 총점이 완전히 동일한 사례는 30.7%에 그쳤다. 이는 교사와 AI가 학생의 전반적인 성취수준을 유사하게 판단하는 경우는 많았지만, 개별 평가요소의 점수와 총점까지 동일하게 판단한 것은 아님을 의미한다.

교과별 성취도 일치율은 역사 95.5%, 수학 95.5%, 영어 72.7%, 과학 59.1%로 교과 간 차이가 비교적 크게 나타났다. 연구 초기에는 정답의 구조와 채점기준이 비교적 명확한 수학·과학 영역에서는 교사-AI 간 판단이 상대적으로 일치하기 쉽고, 학생의

맥락적 이해·논증·표현 등에 대한 질적 판단의 비중이 높은 역사·영어 등의 영역에서는 일치도가 낮을 가능성이 있다고 예상하였다. 그러나 실제 결과에서는 역사과가 수학과 함께 가장 높은 일치율을 보인 반면, 과학과가 가장 낮은 일치율을 나타내어 이러한 초기 예상과 일치하지 않았다. 따라서 교사-AI 채점의 일치도를 교과의 특성만으로 설명하기는 어렵고, 문항의 개방성, 평가요소의 성격, 루브릭 진술의 구체성, 답안의 구조화 정도, 학생의 표현 방식, 손글씨 OCR 인식의 정확성 등이 복합적으로 작용한 결과로 해석할 필요가 있다. 특히 개방적인 서·논술형 문항이라 하더라도 평가요소와 기대수행이 명확하게 구조화되어 있을 경우 높은 일치도를 보일 수 있다는 점은 역사과 결과를 통해 확인할 수 있었다.

평가요소의 성격에 따른 차이도 확인하였다. 4개 교과의 세부 평가요소를 비교한 결과, 정량적 평가요소에서 교사와 AI가 동일한 점수를 부여한 비율은 73.9%, 정성적 평가요소에서는 56.4%로 나타나 정성적 요소에서 판단 차이가 상대적으로 더 자주 발생하였다. 이는 사실적 요소의 포함 여부나 제시된 사례의 수처럼 비교적 명시적으로 확인할 수 있는 기준에서는 AI와 교사의 판단이 일치하기 쉬운 반면, 설명의 적절성, 논거의 타당성, 맥락적 이해, 표현의 완결성 등 종합적인 판단이 필요한 요소에서는 차이가 발생할 가능성이 높음을 보여준다. 다만 교과별 평가요소의 배점 폭과 문항의 개방성, 루브릭의 구체성이 서로 다르므로, 이 결과만으로 AI의 정성적 판단 능력이 낮다고 단정하는 것은 적절하지 않다. 오히려 정성적 판단을 요구하는 평가일수록 루브릭의 진술을 더욱 명확하게 하고, AI의 판단 결과를 교사가 검토하는 절차가 중요하다는 점을 시사한다.

교사들이 불일치 사례를 직접 검토한 결과에서도 공통적인 원인이 확인되었다. 첫째, 학생이 문항에서 요구한 필수 요소를 충분히 작성하지 않았음에도 AI가 해당 요소를 충족한 것으로 판단하여 점수를 부여하는 사례가 있었다. 반대로 학생이 실제로 작성한 내용을 AI가 인식하지 못하여 점수를 낮게 부여하는 경우도 나타났다. 둘째, 손글씨나 수정 흔적, 볼펜 자국 등을 문자로 잘못 인식하는 OCR 오류가 채점 결과에 영향을 주었다. 셋째, 학생의 전체 답안 맥락에서는 의미가 충분히 전달되는 표현임에도 문법적 오류나 표현상의 불완전성을 AI가 과도하게 감점하는 사례가 확인되었다. 넷째, 탐구형·개방형 문항에서는 교사가 평가하고자 한 사고의 질과 AI가 루브릭에 따라 판단한 내용 사이에 차이가 발생하는 경우가 있었다. 이러한 경험을 통해 교사들은 ‘AI가 채점하기 쉬운 문항’을 만들기 위해 평가과제의 개방성이나 교육적 의미를 축소해서는 안 된다는 문제의식을 공유하게 되었다.

성취도 불일치 사례의 크기도 함께 분석하였다. 전체 88건 중 교사와 AI의 최종 성취도가 달랐던 사례는 17건이었으며, 이 가운데 15건은 한 단계 차이, 2건은 두 단계 차이였다. 특히 불일치 17건 중 10건은 교사 또는 AI의 점수가 성취도 분할 점수인 60점·70점·80점·90점의 ±2점 범위에 위치하였다. 즉 실제 총점 차이는

크지 않더라도 분할점수의 경계에 위치한 경우 작은 점수 차이가 A~E 성취도 차이로 확대되는 경계효과가 상당 부분 존재하였다. 그러나 과학과 일부 사례에서는 교사와 AI의 총점 차이가 10점 이상 나타난 경우도 확인되어, 모든 불일치를 분할점수 경계의 문제만으로 설명할 수는 없었다. 이러한 사례는 루브릭 해석, 답안 내용 인식, 질적 판단 등 채점 과정 자체에서 교사와 AI의 판단 차이가 발생할 수 있음을 보여준다.

AI 자체의 채점 일관성도 예비적으로 확인하였다. 동일한 답안을 동일한 AI에 반복하여 채점했을 때 일부 평가요소의 세부 점수는 소폭 달라지는 경우가 있었으나, 관찰한 범위에서는 최종 A~E 성취도를 변경할 정도의 차이는 나타나지 않았다. 또한 동일 답안을 다른 생성형 AI로 채점해 본 비공식적인 비교에서는 전체적인 성적 분포는 크게 다르지 않았으나 일부 학생의 성취도 분류가 달라지는 사례가 나타났다. 다만 이 비교는 동일한 조건에서 체계적으로 반복·기록한 정식 검증 자료가 아니므로 본 연구의 확정적 결과로 제시하기보다는 향후 추가 검증이 필요한 사항으로 보았다.

이상의 결과를 종합하면, 교사-AI 간 80.7%의 성취도 일치율은 AI가 일정 수준의 보조 채점자로 활용될 가능성을 보여주지만, 이를 교사의 최종 판단을 대체할 수 있다는 의미로 해석해서는 안 된다. 오히려 교사와 AI가 서로 다른 판단을 내린 사례를 분석하는 과정에서 문항의 모호성, 루브릭의 불명확한 진술, OCR 인식의 한계, 평가요소의 구조적 문제를 발견할 수 있었다는 점에서 의미가 있었다.

이에 본교는 AI가 채점하기 쉬운 평가를 설계하는 것이 아니라 교육적으로 타당한 평가를 먼저 설계하고, 그 평가 안에서 AI가 어느 범위까지 교사의 판단을 지원할 수 있는지를 결정해야 한다는 원칙을 재확인하였다. 즉 본 연구에서 확인한 AI 채점의 핵심 가치는 교사를 대신해 채점하는 데 있기보다, 교사에게 제2의 판단 기준을 제공하여 자신의 채점과 루브릭을 다시 검토하고 평가의 질을 높이도록 지원하는 데 있다.

교과	A~E 성취도 일치율	평균 절대 점수차	해석상 특징
과학	59.1%	6.5점	교과 중 가장 낮음. 탐구형 답안 해석·필수요건 판단·OCR 등 질적 쟁점이 다수 확인됨
역사	95.5%	1.2점	교과 중 가장 높은 수준. 개방형·정성 문항도 구조화된 루브릭에서 높은 일치 가능성 확인
영어	72.7%	3.4점	평균점수는 거의 동일하나 개별 학생에서는 성취도 경계를 넘는 차이 발생
수학	95.5%	3.5점	총점 완전일치는 낮지만 성취도 분류는 대부분 동일하여 점수 일치와 성취도 일치가 다름을 보여줌
전체	80.7%	3.6점	총점 완전일치 30.7%; 성취도는 71/88건 일치

【표 31】 교과별 교사-AI 비교 채점 결과

※ 해석상 유의점

전체 성취도 일치율 80.7%는 교사와 AI의 세부 점수가 대부분 같았다는 뜻이 아니다. 총점 완전일치는 30.7%였고, 정량 요소의 동일점수 비율(73.9%)이 정성 요소(56.4%)보다 높았다. 따라서 AI 채점의 신뢰도는 최종 성취도 일치율뿐 아니라 평가요소별 점수 차이와 불일치 원인을 함께 분석해야 한다.

AI 채점이 교사의 업무 부담을 실질적으로 경감시켰는가에 대해서는 본교의 학교 규모와 연구 운영 방식까지 함께 고려할 필요가 있다. 본교는 학생 수가 적은 소규모 학교로, 한 교사가 채점해야 하는 서·논술형 답안의 절대적인 수가 대규모 학교에 비해 많지 않기 때문에 답안 채점 자체가 연구 이전부터 과도한 업무 부담으로 작용한 것은 아니었다. 오히려 연구 과정에서는 교사가 학생 답안을 직접 채점하는 것에 더해 AI가 제시한 점수와 채점 근거, 피드백 내용을 다시 확인하고 교사 자신의 판단과 비교·분석해야 했기 때문에, 단순히 교사가 혼자 채점하는 경우보다 더 많은 시간과 노력이 소요되기도 하였다.

그러나 이러한 추가 과정은 단순한 업무 증가로만 볼 수 없었다. 교사는 AI의 채점 결과와 자신의 판단이 일치하는 경우에는 기존 채점 기준의 타당성을 재확인할 수 있었고, 서로 다른 판단이 나타난 경우에는 그 차이가 학생 답안의 해석 차이인지, 루브릭 진술의 모호성인지, OCR 인식 오류인지, 평가요소 자체의 구조적 문제인지를 다시 검토하게 되었다. 특히 AI가 예상과 다른 점수를 부여한 사례를 분석하는 과정은 교사가 평소 직관적으로 적용하던 채점 기준을 보다 명시적으로 설명하고, 루브릭의 표현을 수정·정교화하는 계기로 작용하였다. 즉 AI는 채점 업무를 단순히 대신하는 도구라기보다, 교사의 판단을 다시 점검하게 하는 두 번째 채점자이자 평가도구의 문제를 드러내는 검토 장치로 기능하였다.

따라서 본교의 연구 결과에서 AI 채점의 직접적인 효과를 ‘채점 시간의 단축’이나 ‘업무량의 감소’로 설명하는 것은 적절하지 않다. 본교에서 보다 분명하게 확인된 효과는 비슷한 시간과 노력을 들이더라도 교사가 자신의 채점 판단을 다른 기준과 비교하고, 평가 근거를 보다 명확히 하며, 문항과 루브릭의 질을 개선할 수 있었다는 점이었다. 이러한 경험을 통해 본교는 AI 채점의 가치를 ‘교사가 덜 채점하게 하는 것’보다 ‘교사가 더 근거 있게, 더 일관되게 채점하도록 돕는 것’으로 재해석하였다.

다만 이러한 결과는 소규모 학교라는 본교의 여건과 밀접하게 관련되어 있으므로, 학생 수가 많은 학교에서도 동일한 양상으로 나타난다고 일반화하기는 어렵다. 대규모 학교에서는 AI 활용이 반복적인 채점 업무의 일부를 줄이는 데 보다 직접적인 효과를 보일 가능성도 있으나, 본 연구에서는 이를 실증적으로 확인하지 않았다. 따라서 본교의 결과는 AI 채점의 업무 경감 효과를 단정하기보다, 교사 전문성을 지원하는 질적 협업의 가능성을 확인한 사례로 해석하는 것이 타당하다.

요 약

세부 과제	시기	실행 결과	검증 방법
채점 결과 비교 분석을 통한 평가의 신뢰도 및 타당성 검증	연중	○ 채점 결과 비교 분석 -과학·역사·영어·수학 4개 교과 88건 비교 -최종 성취도 일치율 80.7%	인공지능 내 검증 인공지능 간 검증 교사-AI 간 검증

		-정량요소 동일점수 73.9%, 정성요소 56.4% -OCR·필수요건 판단·문맥 해석 등 불일치 원인 질적 분석 완료 ○ 프롬프트, 루브릭 수정을 통해 신뢰도 확보	

【표 32】 세부 과제 3-다 요약

종합 연구과제 실행 결과 종합

3개 연구과제의 실행 결과를 종합하면, 본 연구는 계획 단계에서 설정한 내용을 단순히 적용·검증하는 데 그치지 않고 실제 평가를 설계하고 적용하는 과정에서 나타난 문제를 분석하고 다시 평가도구와 운영 방식을 개선하는 실행연구의 순환 과정으로 진행되었다. 특히 1학기 적용 결과를 바탕으로 문항과 루브릭, AI 활용 방식, 교과 협의 체제를 지속적으로 수정하면서 연구의 중심이 점차 기술 자체보다 학생의 성취를 제대로 드러내는 평가의 본질로 이동하였다. 그 과정에서 다음과 같은 공통적인 변화와 시사점을 확인하였다.

첫째, 연구의 중심축이 ‘AI를 어떻게 활용할 것인가’에서 ‘학생의 성취를 제대로 드러내는 평가를 어떻게 설계할 것인가’로 이동하였다. 연구 초기에는 AI를 활용하여 서·논술형 평가의 채점 부담을 줄이고 교사-AI 간 채점 일치도를 높이는 것이 중요한 과제로 설정되었다. 이에 따라 자체 개발 프로그램, AI 채점 시스템, 정량·정성 분리형 루브릭 등을 적용하였다. 그러나 실제 운영 과정에서 문항의 평가요소가 모호하거나 루브릭의 기대수행이 충분히 구체적이지 않은 경우에는 AI의 성능과 관계없이 채점 결과의 일관성을 확보하기 어렵다는 점이 확인되었다. 반대로 성취기준을 분석하여 평가요소를 명확히 하고, 이를 탐구질문과 문항, 루브릭에 일관되게 반영한 경우에는 개방적인 서·논술형 평가에서도 비교적 높은 교사-AI 일치가 나타났다. 이에 본교는 성취기준 분석 → 평가요소 도출 → 교실-삶 이음 탐구질문 개발 → 단계별 비계 질문과 핵심 평가 질문 구성 → 루브릭 개발로 이어지는 평가 설계 절차를 공통 원리로 정립하고, AI는 이 과정에서 교사의 판단을 지원하는 도구로 활용하는 방향으로 연구의 초점을 재정립하였다.

둘째, 소규모 학교의 구조적 한계를 교과 간 공동 협의를 통해 보완하면서 평가 전문성 신장의 새로운 가능성을 확인하였다. 본교는 교과별 담당 교사가 1명인 경우가 많아 동일 교과 교사 간 문항 및 루브릭 검토가 어려운 구조를 가지고 있다. 이는 연구 초기에는 평가도구 개발과 검증의 제약으로 인식되었다. 그러나 국어·영어·수학·과학·사회(역사) 담당 교사가 함께 참여하는 공동 협의를 운영하면서 서로 다른 교과의 관점에서 문항의 명확성, 학생의 이해 가능성, 삶과의 연결, 답안작성

조건 등을 검토할 수 있었다. 특히 출제자에게는 분명하게 보이는 질문이나 조건이 다른 교과 교사에게는 모호하게 느껴지는 지점을 확인하면서 평가문항을 학습자 관점에서 다시 점검하는 계기가 되었다. 이러한 과정은 특정 교과의 전문 내용을 대신 판단하는 방식이 아니라, 평가 설계의 공통 원리를 함께 검토하면서 각 교과 교사의 전문적 판단을 보완하는 방식으로 기능하였다. 따라서 소규모 학교의 교과별 1인 교사 체제는 분명한 제약이었지만, 동시에 교과 간 공동 협의를 통해 평가를 다양한 관점에서 성찰하는 계기로 전환될 수 있음을 확인하였다.

셋째, 교사-AI 채점 비교는 AI의 '정확도'를 확인하는 데 그치지 않고 문항과 루브릭, 교사의 채점 판단을 다시 검토하는 자료로 기능하였다. 1학기 과학·역사·영어·수학 4개 교과, 학생 22명의 총 88건의 교과-학생 사례를 비교한 결과 교사와 AI의 최종 A~E 성취도는 71건에서 일치하여 전체 일치율 80.7%를 보였다. 그러나 총점이 완전히 동일한 경우는 30.7%에 그쳤으며, 교과별 성취도 일치율도 역사 95.5%, 수학 95.5%, 영어 72.7%, 과학 59.1%로 차이가 나타났다. 또한 정량 평가요소의 동일 점수 비율은 73.9%, 정성 평가요소는 56.4%로 나타나 평가요소의 성격에 따라서도 차이가 확인되었다. 이는 AI 채점의 일치도가 단순히 교과 특성에 의해 결정되는 것이 아니라 문항의 개방성, 루브릭 진술의 구체성, 답안의 구조, 학생 표현 방식, OCR 인식 정확도 등 여러 요인이 복합적으로 작용한 결과임을 보여주었다. 특히 교사와 AI의 판단이 달랐던 사례를 분석하는 과정에서 필수 요소 누락에 대한 과도한 점수 부여, 학생이 작성한 내용을 놓치는 경우, 손글씨 인식 오류, 문맥상 허용 가능한 표현에 대한 과도한 감점 등이 확인되었으며, 이는 다시 문항과 루브릭의 적절성을 점검하는 계기가 되었다. 따라서 본교에서 AI는 교사를 대신하는 최종 채점자라기보다 교사의 판단과 비교할 수 있는 제2의 채점자이자 평가도구의 문제를 발견하게 하는 검토 장치로서 더 큰 의미를 가졌다.

넷째, 1학기 평가에서 확인한 학생 간 수행 격차를 바탕으로 2학기 평가도구는 '활동의 단계화'에서 '사고의 단계화'로 발전하였다. 1학기 수행평가에서는 상위권 학생들이 대체로 문항에서 요구한 여러 조건을 확인하고 핵심 개념과 근거를 하나의 완성된 답안으로 조직할 수 있었던 반면, 중·하위권 학생들은 교과 내용을 알고 있더라도 여러 조건을 동시에 해석하고 자신의 생각을 문장으로 구성하는 과정에서 어려움을 겪는 경우가 나타났다. 이에 본교는 평가하려는 사고 수준 자체를 낮추는 대신, 학생이 핵심 수행에 도달하기까지의 사고 경로를 작은 단계로 나누어 안내하는 단계별 비계 질문을 도입하였다. 또한 평가도구를 구체화하는 과정에서 모든 단계별 답안을 점수화할 경우 오히려 학생과 교사의 부담이 증가할 수 있다는 점을 고려하여, 배경지식 활성화와 개념 간 관계 파악, 주장·논거·근거 구성 등을 돕는 질문은 무점수 비계 질문으로 활용하고, 성취기준과 평가요소에 직접 연결된 핵심

평가 질문의 답안만 점수화하는 원칙을 설정하였다. 이를 통해 수업 과정에서는 비계와 피드백으로 학습을 지원하고, 핵심 수행에서는 성취수준을 판단하는 구조로 평가를 개선하였다.

다섯째, 이러한 변화는 '이음형 표준 루브릭'과 '교사-AI 협업'의 의미도 함께 재정립하는 결과로 이어졌다. 1학기에는 AI와 교사의 역할을 구분하고 채점 일치도를 높이기 위해 하나의 평가요소를 정량·정성 영역으로 세분화하였으나, 실제 적용 과정에서 모든 평가요소를 인위적으로 분리하는 것이 교사의 업무를 증가시키고 정량과 정성의 경계 역시 명확하지 않다는 한계가 나타났다. 이에 2학기에는 평가요소의 성격을 먼저 판단하고 성취기준에서 요구하는 수행을 하나의 기대수행으로 통합하여 진술하는 방향으로 루브릭을 개선하였다. 이에 따라 '표준'의 의미도 모든 교과가 동일한 형식의 루브릭을 사용하는 것이 아니라, 성취기준에서 평가요소를 도출하고 문항과 루브릭을 일관되게 연결하는 공통된 설계 원리와 절차를 공유하는 것으로 재해석하였다. 교사-AI 협업 역시 AI가 교사의 채점 업무를 대신하는 체제가 아니라, 교사가 교육과정과 학생에 대한 전문적 판단을 바탕으로 평가의 목적과 기준을 설계하고 AI는 평가도구 개발·채점·분석·피드백 과정에서 그 판단을 지원하는 체제로 구체화되었다.

종합하면, 본 연구의 가장 중요한 성과는 특정 AI 프로그램의 활용 효과나 높은 채점 일치율 자체에 있기보다, AI를 실제 평가에 적용하는 과정에서 오히려 좋은 서·논술형 평가란 무엇인지, 성취기준과 문항·루브릭은 어떻게 연결되어야 하는지, 학생의 사고를 지원하면서 성취를 어떻게 판단해야 하는지에 대한 학교 구성원의 이해가 구체화되었다는 데 있다. 또한 교사-AI 간 불일치, 1학기 문항 적용 과정에서 나타난 학생의 어려움, 정량·정성 분리형 루브릭의 한계와 같은 시행착오는 연구의 실패가 아니라 2학기 평가도구와 협업 체제를 개선하는 근거로 활용되었다. 이는 본 연구가 계획 → 실행 → 관찰 → 성찰 → 개선의 순환을 통해 미래형 학생평가 모델을 점진적으로 정교화해 온 실행연구임을 보여준다.

Ⅵ 연구의 검증 및 일반화 결과

1 연구 검증 결과

연구의 신뢰도와 타당성을 확보하기 위해 '자체 검증 루브릭', '만족도 조사' 등 다각적인 검증 계획을 수립하여 운영하였다.

가. 연구 성과 자체 검증

연구의 성과를 객관적으로 평가하기 위해 아래와 같은 '자체 검증 루브릭'을 활용하여 7월에 1차 자체 검증을 완료하였다.(11월 2차 자체 검증 실시 예정)

□ 연구학교 운영 성과 1차 자체 검증 결과(7월)

영역	세부 영역	평가 내용	평가 결과
여건 조성 [과제1]	제도적 기반	서·논술형 평가 확대를 위한 학업성적 관리규정 개정 및 안착이 이루어졌는가?	상 — 계획에 따라 관련 규정을 개정·적용하였으며, 과정중심평가 집중운영기간 등 평가 운영을 지원하는 세부 기반을 마련함.
	인적 기반	교원 연수를 통해 교사의 평가 전문성 및 AI 활용 역량이 실질적으로 향상되었는가?	상 — 7월까지 4회의 연수를 실시하였으며, 연구 진행 과정과 교사 수요를 반영하여 연수 내용과 방향을 유연하게 조정함. (10월 성취평가 심화연수 2회 예정)
모델 구축 [과제2]	이음-평가 모델	이음-평가 모델이 이음 교육과정의 철학 [교육과정-수업-평가-피드백 이음]을 체계적으로 반영했는가?	중 — 성취기준에 기반한 수업·평가 설계는 비교적 안착하였으나, 평가 결과를 피드백과 후속 학습으로 연결하는 과정은 추가 보완이 필요함.
	삶-연계 서·논술형 평가 모형	탐구 질문 중심의 문항이 학생의 삶과 연계되어 고등사고력을 측정했는가?	상 — 교과별 교실-삶 이음 탐구질문과 서·논술형 문항을 개발·적용하였으며, 1학기 적용 결과를 토대로 단계별 비계 질문 등 개선 방향을 도출함.
AI 채점 [과제3]	교사 신뢰도	AI-교사 간 신뢰도 확보 및 채점 관점 차이에 대한 심층 질적 분석이 이루어졌는가?	중 — 최종 성취도에서 높은 수준의 일치 가능성을 확인하였으나, 교과별 편차와 세부 점수 차이가 나타나 추가적인 검증과 분석이 필요함.
	AI 효율성	AI 협업 모델이 교사의 채점 시간을 실질적으로 경감시켰는가?	중 — 직접적인 채점 시간 절감 효과는 제한적이었으나, AI와의 비교채점을 통해 루브릭과 채점 판단을 점검·정교화하는 질적 효과를 확인함.

【표 33】 1차 자체 검증 결과

자체 검증 결과를 종합하면, 연구학교 운영을 위한 제도적·인적 기반과 '교실-삶 이음' 서·논술형 평가도구 개발은 계획에 따라 비교적 안정적으로 추진된 것으로 평가하였다. 제도적 측면에서는 서·논술형 평가 확대를 위한 학업성적관리규정과 평가 운영 방식을 계획에 따라 개정·적용하였으며, 정기시험 횟수 조정, 수행평가 반영 비율 확대, 과정중심평가 집중운영기간 운영 등 평가 개선을 지속적으로 지원할 수 있는 세부 운영 기반을 마련하였다. 인적 측면에서도 7월까지 4회의 교원 연수를 실시하였으며, 연구 진행 과정에서 확인된 교사의 요구와 연구 방향의 변화를

반영하여 AI 활용뿐 아니라 성취평가, 루브릭 및 평가도구 설계 등으로 연수 내용을 유연하게 조정하였다. 이를 통해 교사가 성취기준을 분석하고 평가요소·문항·루브릭을 연계하여 설계하는 평가 전문성을 높일 수 있는 기반을 마련하였다.

‘교실-삶 이음’ 서·논술형 평가도구도 1학기 실제 적용을 통해 성과와 개선 과제를 구체적으로 확인하였다. 교과에서 학습한 지식과 개념을 학생의 실제 삶과 사회 문제에 적용·확장할 수 있도록 교과별 탐구질문과 서·논술형 문항을 개발·적용하였다. 대표 학생 답안과 교사 관찰 결과, 상위권 학생들은 대체로 문항에서 요구한 조건을 파악하고 핵심 개념과 근거를 비교적 충실하게 조직한 반면, 중·하위권 학생들은 여러 답안작성 조건을 동시에 해석하고 자신의 사고를 글로 구조화하는 과정에서 어려움을 겪는 사례가 나타났다. 이에 1학기 문항의 한계를 단순한 장문 작성 능력의 문제로 보기보다, 복합적인 사고 과정과 답안작성 조건을 학생 스스로 조직해야 하는 문항 구조가 교과 성취 이외의 글쓰기와 조건 해석 능력에 영향을 받을 수 있다는 점으로 해석하였다. 이를 바탕으로 2학기에는 평가에서 요구하는 사고 수준은 유지하되 학생이 핵심 수행에 도달하는 사고 경로를 세분화할 수 있도록 단계별 비계 질문을 도입하고 문항과 루브릭의 구조를 보다 정교화하는 방향을 설정하였다.

교사-AI 협업 채점에서는 4개 교과의 실제 원자료 분석을 통해 AI 활용의 가능성과 한계를 함께 확인하였다. 과학·역사·영어·수학 4개 교과에서 2학년 학생 22명의 총 88건 사례를 분석한 결과, 교사와 AI의 최종 성취도는 71건에서 일치하여 전체 일치율 80.7%를 보였다. 그러나 교과별 일치율은 역사와 수학 95.5%, 영어 72.7%, 과학 59.1%로 차이가 있었으며, 세부 점수와 평가요소별 판단에서도 불일치 사례가 확인되었다. 이는 AI 채점의 신뢰성을 전체 일치율만으로 판단하기보다 문항의 구조, 루브릭 진술의 구체성, 평가요소의 성격, 학생의 표현 방식, OCR 인식 정확도 등을 함께 고려해야 함을 보여주었다. 또한 본교에서는 AI 채점이 직접적인 채점 시간 단축으로 이어지기보다는, 교사가 자신의 판단과 AI의 채점 결과를 비교하면서 문항과 루브릭의 모호성을 확인하고 채점 근거를 다시 점검하는 제2의 채점자이자 검토 도구로서 의미가 있음을 확인하였다.

한편 7월 자체검증 시점에서는 ‘이음-평가 모델’의 교육과정-수업-평가-피드백 전 과정이 충분히 안착되었다고 판단하기에는 한계가 있었다. 1학기에는 평가문항과 루브릭 개발, 교사-AI 비교채점, 교과 공동 협의 등 평가 설계와 채점 체제 구축에 연구 역량이 집중되면서, 평가 결과를 학생의 재학습과 후속 활동으로 연결하는 피드백 단계는 상대적으로 충분히 운영되지 못하였다. 또한 단계별 비계 질문과 개선된 루브릭은 1학기 운영 결과를 바탕으로 도출한 2학기 개선 방향으로, 자체검증

시점에서는 실제 성적 반영 평가에 적용하기 전이었으므로 그 효과를 판단하기보다 향후 적용·검증이 필요한 과제로 보았다.

따라서 7월 자체검증 결과, 연구학교 운영을 위한 제도적·인적 기반 조성, 교실-삶 이음 평가문항 개발·적용, 교사-AI 채점 비교 체제 구축은 계획에 따라 추진되고 있었으며, 1학기 실행 과정에서 확인된 결과를 토대로 학생의 사고를 지원하는 문항 구조의 개선, 루브릭의 정교화, 평가와 피드백의 연계 강화를 2학기 중점 보완 방향으로 설정하였다. 특히 연구 초기 AI 활용과 채점 일치도에 집중되었던 연구의 관심이 실제 운영을 거치면서 학생의 성취를 보다 타당하게 드러내는 평가를 어떻게 설계할 것인가의 문제로 확장되었다는 점을 자체검증의 중요한 성과로 판단하였다.

나. 만족도 조사 결과

연구학교 운영에 따른 학생과 교사의 인식 변화를 확인하기 위해 정량 설문과 면담을 병행하는 방식으로 만족도 조사를 구성하였다. 정량 설문은 5점 Likert 척도를 활용하여 서·논술형 평가에 대한 인식, 교실-삶 이음 평가, 단계별 비계 질문, AI 활용 및 평가 신뢰도, 평가 부담, 교사의 평가 전문성 등을 중심으로 구성하였으며, 면담에서는 설문 결과만으로 파악하기 어려운 구체적인 경험과 이유, 개선 의견을 추가로 확인하였다.

□ 학생 만족도 조사 결과(2학년 22명)

영역	세부 조사 내용	긍정 응답률(%)
서·논술형 평가 인식	서·논술형 평가가 학습 내용의 이해와 자신의 생각을 표현하는 데 도움이 되었는가	86.4
교실-삶 이음 평가	교과에서 배운 내용을 실제 생활이나 사회 문제와 연결하는 평가가 의미 있다고 생각하는가	90.9
평가문항 이해	질문의 의도와 답안작성 조건을 확인하며 답을 작성하게 되었는가	81.8
단계별 비계 질문	단계별 질문이 글쓰기 부담을 줄이고 생각을 순서대로 정리하는 데 도움이 되었는가	72.7
논리적 표현	주장과 이유·근거를 구분하여 자신의 생각을 표현하는 데 도움이 되었는가	81.8
평가 운영 방식	정기시험 횟수 축소와 수행평가 확대 방식이 학생의 학습과 성취를 평가하는 데 적절한가	95.5
AI 활용 신뢰	AI 채점 결과를 교사가 확인하고 최종 판단하는 방식이 필요하다고 생각하는가	90.9

【표 34】 학생 만족도 조사 결과

학생 면담에서는 서·논술형 평가에 대한 부담과 부정적 인식이 연구 초기보다 완화되었다는 의견이 주로 나타났다. 반복적인 평가 경험을 통해 서·논술형 평가를 단순히 긴 글을 작성하는 평가라기보다, 배운 내용을 바탕으로 자신의 생각과 판단을 표현하는 평가로 이해하게 되었다는 반응이 있었다. 특히 교과에서 배운 내용을

자신의 생활이나 사회 문제와 연결하여 생각하도록 하는 교실-삶 이음 평가에 대해서는 비교적 높은 만족감을 나타냈다.

단계별 비계 질문에 대해서는 의견이 다소 엇갈렸다. 한 번에 긴 답안을 작성하는 것보다 질문이 단계적으로 제시되어 무엇부터 생각하고 작성해야 하는지를 파악하는 데 도움이 되었고 글쓰기 부담이 줄었다는 의견이 나타났다. 반면 일부 학생은 서·논술형 평가 자체가 여전히 어렵다고 느끼거나, 단계별 질문으로 인해 답해야 할 문항 수가 많아져 오히려 부담스럽다는 의견을 제시하였다. 이는 비계 질문을 많이 제시하는 것 자체가 목적이 아니라, 학생의 핵심 수행을 지원하는 데 필요한 질문을 적절한 수준으로 선별할 필요가 있음을 보여준다.

AI 채점에 대해서는 AI 자체의 오류나 공정성에 대한 우려보다는 교사가 설정한 평가기준과 루브릭이 얼마나 공정하고 일관되게 적용되는가에 대한 관심이 상대적으로 크게 나타났다. AI가 독립적으로 최종 점수를 결정하기보다는 교사의 채점 결과를 다시 확인하고 보완하는 방식으로 활용할 경우 평가의 신뢰성을 높일 수 있다는 기대도 확인되었다. 또한 정기시험 횟수 축소에 대해서는 시험 준비와 평가에 대한 부담이 감소했다는 긍정적인 의견이 주로 나타났다.

□ 교사 만족도 조사 결과(교사 10명/비교과 담당 교사 제외)

영역	세부 조사 내용	긍정 응답률(%)
서·논술형 평가 인식	연구학교 운영을 통해 서·논술형 평가의 목적과 의미를 이전보다 명확하게 이해하게 되었는가	90
평가도구 개발 역량	성취기준을 분석하여 평가요소를 도출하고 문항과 연결하는 역량이 향상되었는가	90
교실-삶 이음 문항	교과 지식을 학생의 삶이나 사회 문제와 연결하는 평가문항 개발 역량이 향상되었는가	80
단계별 비계 질문	단계별 질문이 학생의 사고과정을 드러내고 글쓰기 부담을 완화하는 데 도움이 되었는가	80
평가요소 간 연계	성취기준·평가요소·문항·루브릭 간 연계성에 대한 인식이 높아졌는가	90
AI 활용 방향	AI를 교사의 채점을 대신하기보다 평가도구 개발과 채점 판단을 지원하는 도구로 활용하는 것이 적절한가	100
AI 교차채점	AI와 교사의 채점 결과 비교가 루브릭 및 평가도구 개선에 도움이 되었는가	90
평가 운영 개선	정기시험 횟수 조정과 공동 협의 운영이 수행평가의 내실화에 도움이 되었는가	100
평가 전문성	연구학교 운영과 AI 활용 경험이 교사의 평가 전문성 향상에 도움이 되었는가	100

【표 35】 교사 만족도 조사 결과

교사 면담에서는 연구학교 운영을 통해 서·논술형 평가를 바라보는 관점과 평가 도구를 개발하는 방식이 변화하였다는 의견이 주로 나타났다. 특히 성취기준을 분석하여 평가요소를 도출하고, 이를 문항과 루브릭으로 연결하는 과정을 반복하면서

평가도구의 타당성과 일관성을 이전보다 중요하게 고려하게 되었다는 의견이 있었다.

AI 활용과 관련해서는 업무 경감 효과와 평가 전문성 향상 효과가 서로 다르게 나타났다. AI와 교사의 채점 결과를 비교함으로써 자신의 채점 판단을 다시 확인하고, 문항이나 루브릭의 모호한 부분을 발견할 수 있었다는 점에서는 긍정적인 평가가 많았다. 특히 예상하지 못한 AI의 채점 결과를 검토하는 과정에서 교사가 자신의 평가기준을 보다 구체적으로 설명하고 평가도구를 수정·보완하게 되었다는 점이 평가 전문성 향상에 도움이 된 것으로 나타났다.

반면 AI를 활용한 교차채점이 교사의 업무 부담을 직접적으로 줄였다고 보기는 어려웠다. 교사가 학생 답안을 직접 채점한 뒤 AI의 점수와 근거를 다시 확인하고 불일치 사례를 분석해야 했기 때문에, 연구 과정에서는 오히려 추가적인 시간과 노력이 필요하다는 의견도 있었다. 따라서 교사들은 AI의 효과를 단순한 '채점 시간의 절감'보다는 '채점의 근거와 평가도구를 다시 검토하게 하는 보조적 역할'에서 더 크게 인식하였다.

평가 운영 측면에서는 정기시험 횟수를 축소함으로써 시험 출제와 채점에 집중되던 부담이 완화되고, 수행평가 문항과 루브릭을 보다 충분히 검토할 수 있는 여건이 마련되었다는 의견이 나타났다. 또한 국어·영어·수학·과학·사회 교사가 함께 참여한 공동 협의를 통해 다른 교과의 관점에서 자신의 평가도구를 검토할 수 있었다는 점도 긍정적으로 평가되었다.

□ 만족도 조사 종합

학생과 교사의 만족도 조사 결과를 종합하면, 연구학교 운영을 통해 서·논술형 평가에 대한 인식 개선, 교실-삶 이음 평가에 대한 긍정적 수용, 평가 부담 완화, 교사의 평가 전문성 향상이 주요 변화로 나타났다.

특히 학생에게는 배운 내용을 삶의 맥락에서 생각하고 자신의 의견을 표현하는 평가 경험이 확대되었으며, 교사에게는 AI와의 비교채점을 통해 자신의 문항·루브릭·채점 판단을 다시 검토하는 기회가 제공되었다. 이는 AI의 도입 자체보다 AI를 활용하는 과정에서 평가의 목적과 기준을 다시 성찰하게 된 것이 이번 연구의 중요한 성과임을 보여준다.

다만 단계별 비계 질문에 대해서는 글쓰기와 사고 조직에 도움이 되었다는 긍정적 의견과 함께 질문의 수가 많아져 부담스럽다는 의견도 확인되었다. 또한 AI 교차채점 역시 평가의 신뢰도 향상에는 도움이 되었으나 교사의 업무량을 직접 감소시키지는 못하였다. 따라서 단계별 비계 질문은 핵심 수행을 지원하는 수준으로 정교화하고, AI 역시 교사의 판단을 대체하기보다 교사의 평가 판단을 확인하고 보완하는 협업 도구로 활용하는 것이 적절한 것으로 판단하였다.

2 일반화 결과

당초 연구 설계에서는 성과 공유를 1차 중간 보고회(7월)와 2차 최종 성과 보고회(11월)의 2단계 절차로 구성하였다. 이는 연구 성과를 정량적으로 일반화하기보다 실천 과정에서 확인된 질적 성과와 개선 가능성을 중심으로 공유하고자 한 연구의 성격을 반영한 것으로, 중간 시점에는 운영 과정의 문제점과 개선 과제를 점검하여 2학기 연구에 반영하고, 최종 시점에는 연구 결과와 일반화 자료를 종합적으로 공유하는 단계적 환류 구조로 설계하였다. 실제 운영에서는 별도의 1차 중간 보고회를 개최하기보다, 실천 단계 컨설팅과 중간평가 자료 작성, 5차 협의회를 통해 1학기 운영 결과를 점검하고 2학기 개선 방향을 도출하는 방식으로 1차 성과 공유 및 환류 절차를 운영하였다.

가. 연구학교 성과 공유

순	종류	시기	내용
1차	중간 보고회	7월	실천단계 컨설팅 및 중간평가 자료(작성기준일 7/13) 및 5차 협의회(7/21)로 갈음하여 진행
2차	최종 성과 보고회	11월	‘교사-AI 협업’ 1년 검증 결과(질적 검증 사례)를 발표하고 일반화 자료집 공유
연수	교사 대상 연수 개설		울산광역시교육연수원과의 협의는 아직 진행 전. 연구학교 담당 교사가 현재 교육청 학생평가 연수강사로 활동 중이어서 향후 관련 연수 개설 시 연계 가능성을 확인함

【표 36】 연구학교 성과 공유 일정

나. 서·논술형 평가 모형 및 AI 활용 평가 채점 자료집 제작 및 홍보

당초에는 연구 성과의 일반화를 위해 ‘이음-평가 탐구질문 문항 모음’과 ‘AI 채점 협업 매뉴얼’의 2종 자료집을 제작하는 것으로 구상하였다. 그러나 실제 평가도구를 개발·적용하는 과정에서 모든 성취기준에 대해 문항을 일률적으로 개발하기보다, 교과별 대표 성취기준을 선정하여 실제 수업과 평가에 활용할 수 있는 사례 중심의 자료를 제공하는 것이 현장 활용성이 높다고 판단하였다. 이에 첫 번째 자료집인 「교실과 삶을 잇다」는 교과별 대표 성취기준을 바탕으로 성취기준 분석 → 평가 요소 도출 → 교실-삶 이음 탐구질문 → 단계별 비계 질문 → 핵심 평가 질문 → 루브릭으로 이어지는 평가도구 개발 과정을 실제 적용 및 일반화 사례 중심으로 제시하는 방향으로 구체화하였다.

루브릭 역시 모든 문항에 동일한 형식을 일괄 적용하기보다 교과와 평가과제의 특성을 반영한 대표 사례와 개발 원리를 함께 제시하여, 교사가 자신의 교과와 학생 특성에 맞게 수정·활용할 수 있도록 구성하였다. 또한 1학기 적용 결과에서 확인된 학생의 글쓰기 및 사고 조직 부담을 반영하여, 모든 단계의 답안을 점수화하지 않고 학생의

사고 형성을 지원하는 단계별 비계 질문과 성취기준·평가요소에 직접 연결된 핵심 평가 질문을 구분하여 제시하였다. 이를 통해 완성된 문항을 단순히 제공하는 자료집이 아니라 교사가 평가도구의 개발 원리를 이해하고 새로운 문항을 스스로 설계·변형할 수 있도록 지원하는 실천 중심의 사례집으로 제작하였다.

두 번째 자료집인 「AI, 교사를 돕다」는 당초의 AI 채점 협업 중심 매뉴얼에서 연구 과정에서 자체 개발한 AI 기반 평가도구 개발 프로그램의 활용 매뉴얼로 방향을 구체화하였다. 자체 개발 프로그램의 성취기준·성취수준 분석 → 평가요소 도출 → 교실-삶 이음 탐구질문 개발 → 단계별 비계 질문 및 핵심 평가 질문 설계 → 루브릭 개발 과정을 중심으로 프로그램의 기능과 활용 절차를 안내하고, AI가 생성한 결과를 교사가 교육과정·수업 내용·학생 수준에 따라 검토·수정·보완하는 방법을 함께 제시하였다. 자료집 제작 과정에서는 AI를 초안 생성과 자료 정리에 보조적으로 활용하되, 본교의 실제 적용 사례와 일반화를 위해 추가 개발한 사례를 구분하여 제시함으로써 특정 AI의 결과를 그대로 사용하는 것이 아니라 교사의 전문적 판단을 바탕으로 평가도구를 개발하는 과정 자체를 일반화하고자 하였다.

주 제	내 용
‘교실과 삶을 잇다’ 교실-삶 이음 서·논술형 평가 사례집	교과별 대표 성취기준을 바탕으로 성취기준 분석 → 평가요소 도출 → 교실-삶 이음 탐구질문 → 단계별 비계 질문·핵심 평가 질문 → 루브릭 개발의 과정을 실제 적용 사례 중심으로 제시하고, 학생 답안과 교사 피드백, 평가도구 개선 사례 등을 수록한 실천형 자료집
‘AI, 교사를 돕다’ AI 기반 평가도구 개발 프로그램 활용 매뉴얼	학교에서 자체 개발한 AI 기반 평가도구 개발 프로그램을 활용하여 성취기준·성취수준 분석 → 평가요소 도출 → 교실-삶 이음 탐구질문 개발 → 단계별 비계 질문·핵심 평가 질문 설계 → 루브릭 개발을 수행하는 절차와 방법을 안내하고, 단계별 프로그램 활용 방법, 생성 결과의 검토·수정·보완 방법, 교사의 최종 판단 원칙 및 AI 활용 시 유의사항 등을 제시한 현장 활용 매뉴얼

【표 37】 자료집

다. 교사-AI 협업 평가도구 개발 프로그램 및 활용 방법 공유

① 학기단위 성취수준 생성기(GPT 연동), ② 중학교 성취기준 분석 및 재구성 프로그램, ③ 교실-삶 이음 서·논술형 평가문항 개발 프로그램, ④ 교사-AI 협업 학생평가 설계 도우미를 개발하여 중학교 전 교과에서 활용할 수 있도록 학교 누리집에 게시하였다. 이들 프로그램은 교사의 평가 판단을 대신하기보다 성취기준 분석, 평가요소 도출, 탐구질문 및 평가문항 개발 등 평가도구 설계 과정에서 교사의 판단을 지원하는 도구로 개발하였다. 다만 별도의 사용자 인증이나 사용 이력 관리 기능을 두지 않아 교과별 활용 횟수나 외부 사용 규모를 정량적으로 확인하는 데에는 한계가 있었다.

연구 초기에는 자체 개발 프로그램의 기능과 활용 방법을 공유함으로써 AI 기반

평가도구 개발을 확산하는 데 비교적 큰 비중을 두었다. 그러나 실제 연구를 진행하면서 특정 프로그램이나 생성형 AI의 사용 방법을 동일하게 적용하는 것보다, 학생의 성취를 타당하게 드러낼 수 있는 평가도구를 어떤 절차로 설계하는가를 공유하는 것이 일반화 측면에서 더욱 중요하다는 점을 확인하였다. 실제 교사들은 자체 개발 프로그램뿐 아니라 다양한 생성형 AI를 교과와 평가 상황에 따라 선택적으로 활용하였으며, AI를 어느 단계에서 어느 정도 활용하는지도 교사별로 차이가 있었다.

이에 일반화의 중심을 특정 AI 도구의 활용법에서 '성취기준 분석 → 평가요소 도출 → 교실-삶 이음 탐구질문 개발 → 단계별 비계 질문 및 핵심 평가 질문 설계 → 루브릭 개발'로 이어지는 평가도구 개발의 공통 원리와 절차로 전환하였다. 즉, 표준화해야 할 것은 특정 AI의 사용 방식이 아니라 교육과정과 수업, 평가를 일관되게 연결하고 학생의 성취를 적절하게 드러내기 위한 평가 설계의 원리와 과정이라는 방향으로 연구 성과의 일반화 범위를 구체화하였다.

또한 연구학교 담당 교사가 울산광역시교육청 학생평가 관련 지원단 및 연수강사로 활동하고 있어, 연구 과정에서 정립한 평가도구 개발 원리와 교사-AI 협업 사례를 학교 내부에만 머무르게 하지 않고 교원 연수와 평가 지원 활동을 통해 현장에 공유할 수 있는 확산 기반을 확보하였다. 향후 관련 연수 자료를 구성할 때에도 특정 프로그램의 사용법을 중심으로 제시하기보다, 실제 평가도구 개발·적용 사례와 교사-AI 채점 비교 결과를 활용하여 교사가 자신의 교과와 학생 특성에 맞는 평가를 설계하고 AI를 선택적으로 활용할 수 있도록 지원하는 방향으로 연구 성과를 공유하고자 한다.

라. 핵심 교과 밖으로의 확산 사례

연구학교의 평가도구 개발과 적용은 국어·영어·수학·과학·사회(역사) 등 핵심 교과를 중심으로 이루어졌으나, 체육 교과에서도 자발적으로 서·논술형 평가를 도입하여 수행 전략을 돌아보고 개선 방향을 서술하거나 자기평가를 실시하는 사례가 확인되었다. 전 교과에 동일한 평가 모형이 정착하였다고 말하기는 아직 이르지만, 서·논술형 평가에 대한 관심이 핵심 교과 밖으로 확장될 가능성을 보여주는 사례로 볼 수 있다. 또한 문항·루브릭 개발을 직접 담당하지 않은 교사들도 연수 운영, 홍보, 학교 누리집 관리 등의 업무를 분담하며 연구학교 운영 전반에 참여하였고, 4월 2일 학교공개의 날에는 학생·학부모를 대상으로 연구학교의 목적과 운영 방향을 사전에 안내하여 서·논술형 평가 확대와 AI 채점에 대한 우려를 초기 단계에서 완화하고자 하였다.

Ⅶ 연구 결과 및 제언

1 연구결과

본 연구는 2022 개정 교육과정의 취지를 반영하여 ‘교실-삶 이음’ 서·논술형 평가를 개발·적용하고, 평가도구 개발과 채점 과정에서 AI가 교사의 전문적 판단을 지원하는 ‘교사-AI 협업’ 평가 체제를 탐색하였다. 연구 결과는 다음 세 가지로 요약할 수 있다.

첫째, 서·논술형 평가의 핵심은 답안의 길이나 문항의 형식이 아니라 학생의 교과 성취와 사고과정을 타당하게 드러내는 평가 설계에 있음을 확인하였다. 성취기준 분석에서 평가요소를 도출하고 이를 교실-삶 이음 탐구질문, 단계별 비계 질문, 핵심 평가 질문, 루브릭으로 연결하는 공통적인 평가 설계 절차를 정립하였다. 특히 1학기 적용 결과를 바탕으로 모든 질문을 점수화하기보다 학습을 지원하는 무점수 비계 질문과 성취 판단을 위한 핵심 평가 질문을 구분하는 방향으로 평가도구를 개선하였다.

둘째, 교사-AI 협업의 중심을 ‘AI가 대신 평가하는 체제’에서 ‘AI가 교사의 평가 판단을 지원하는 체제’로 재정립하였다. 자체 개발 AI 프로그램은 성취기준 분석, 평가요소 도출, 탐구질문 및 문항 개발 등 평가도구 설계를 지원하는 방향으로 발전시켰으며, 실제 채점에서는 교사와 AI가 각각 독립적으로 판단한 결과를 비교·검토하였다. 4개 교과 88건의 사례에서 최종 성취도 일치율은 80.7%였으나 교과별 편차와 세부 점수 차이도 확인되었다. 이를 통해 AI는 최종 판단을 대신하기보다 제2의 채점자로서 교사의 판단을 재검토하고 문항과 루브릭의 문제점을 발견하는 데 의미가 있음을 확인하였다.

셋째, 평가의 질을 높이기 위해서는 교사의 평가 전문성과 이를 지원하는 학교 차원의 운영 여건이 함께 필요함을 확인하였다. 정기시험 횟수 조정과 공동 협의 운영은 교사가 수행평가 문항과 루브릭을 보다 충분히 설계·검토할 수 있는 여건을 마련하였으며, 서로 다른 교과 교사가 함께 평가도구를 검토하는 과정은 소규모 학교의 동교과 협의 한계를 보완하는 전문성 신장 방식으로 기능하였다.

종합하면 본 연구는 특정 AI 도구나 하나의 표준화된 루브릭을 개발하는 것보다, 학생의 성취를 제대로 드러낼 수 있는 평가를 먼저 설계하고 그 과정에서 AI가 교사의 전문적 판단을 적절히 지원하도록 역할을 설정하는 것이 미래형 학생평가의 핵심임을 확인하였다.

2 연구의 한계

본 연구는 실제 학교의 교육과정과 평가 운영 속에서 미래형 학생평가 모델을 개발·적용하였다는 점에서 의미가 있으나, 연구 결과를 해석하고 일반화하는 데에는 다음과 같은 한계가 있다.

첫째, 실질적인 연구 운영 기간이 충분하지 못하였다. 연구학교 운영은 1년이지만 실제 평가도구를 개발하고 학생에게 적용하여 결과를 분석한 뒤 다시 개선안을 적용할 수 있는 기간은 약 8개월에 불과하였다. 이에 1학기에는 평가도구 개발과 적용, 문제점 발견에 많은 시간이 소요되었고, 이를 토대로 개선한 단계별 비계 질문과 통합형 루브릭을 2학기에 다시 적용하여 충분한 자료를 축적하는 데 시간적 제약이 있었다. 특히 연구학교 운영에서는 개발 → 적용 → 분석 → 개선 → 재적용 → 재검증의 순환이 중요한데, 본 연구에서는 이러한 순환을 충분한 횟수로 반복하지 못하였다.

둘째, 소규모 단일 학교를 대상으로 한 연구이므로 연구 결과의 일반화에 주의가 필요하다. 교사-AI 비교 채점도 2학년 학생 22명의 4개 교과, 총 88건을 대상으로 이루어졌기 때문에 80.7%의 성취도 일치율을 AI 채점의 일반적인 신뢰도 수준으로 해석해서는 안 된다. 교과별 일치율 역시 59.1%에서 95.5%까지 차이가 나타났으므로, AI 채점 결과는 교과 자체보다 문항의 구조, 루브릭의 구체성, 학생 답안의 형태, OCR 인식 정확도 등 다양한 요인의 영향을 받는 것으로 보아야 한다.

셋째, 교육과정-수업-평가-피드백의 전 과정 중 피드백과 재학습 단계에 대한 검증이 상대적으로 부족하였다. 1학기에는 평가문항과 루브릭 개발, 교사-AI 비교채점에 연구 역량이 집중되면서 평가 결과를 학생의 재학습과 후속 활동으로 연결하는 과정이 충분히 이루어지지 못하였다. 미래형 학생평가가 학생의 성장을 지원하기 위해서는 채점의 정확성뿐 아니라 평가 결과가 학생의 다음 학습과 어떻게 연결되는지를 검증할 필요가 있다.

넷째, 단계별 비계 질문의 효과도 보다 세밀한 검증이 필요하다. 비계 질문이 한 번에 긴 답안을 작성하는 부담을 줄이고 학생의 사고를 구조화하는 데 도움이 되는 사례가 있었으나, 일부 학생에게는 답해야 할 질문 수가 증가하면서 오히려 부담으로 작용할 가능성도 확인되었다. 따라서 비계 질문의 효과를 단순히 질문의 유무로 판단하기보다 학생의 성취수준, 교과 특성, 질문의 수와 제시 방식에 따라 분석할 필요가 있다.

다섯째, 교사와 학생의 인식 변화 자료만으로 실제 평가 역량이나 학업 성취의 변화를 단정하기 어렵다. 만족도 조사와 면담은 연구 참여자의 경험과 인식 변화를 파악하는 데 의미가 있으나, 이러한 결과가 실제 학생의 사고력이나 교사의 평가 전문성 향상으로 어느 정도 이어졌는지는 학생 답안의 변화, 평가도구의 질적 변화 등 다양한 자료를 함께 활용하여 장기적으로 확인할 필요가 있다.

3 제언

본 연구의 결과와 한계를 바탕으로 미래형 학생평가의 현장 정착을 위해 다음과 같이 제언한다.

첫째, 서·논술형 평가 확대는 평가 비율이나 문항 수를 늘리는 방식보다 교사의 평가 설계 전문성을 강화하는 방향으로 추진되어야 한다. 학생의 사고를 평가하기 위해서는 성취기준을 해석하여 평가요소를 도출하고, 평가요소와 문항·루브릭을 일관되게 연결하는 역량이 선행되어야 한다. 따라서 교원 연수 역시 AI 도구의 단순 활용법보다 성취기준 분석 → 평가요소 도출 → 탐구질문 개발 → 비계 및 핵심 평가 질문 설계 → 루브릭 개발의 실제적인 평가 설계 과정을 중심으로 구성할 필요가 있다.

둘째, AI 활용 정책은 '교사를 얼마나 대신할 수 있는가'보다 '교사의 어떤 판단을 지원할 수 있는가'를 중심으로 설계할 필요가 있다. 현재 단계에서 AI는 평가목표와 기준을 최종적으로 결정하는 주체라기보다 평가문항과 루브릭의 초안을 제안하고, 채점 결과를 교사와 비교하여 판단을 점검하는 보조적 역할에 강점이 있다. 따라서 AI의 최종 자동채점을 목표로 하기보다 교사 최종 판단을 전제로 한 제2의 채점자 또는 검토 도구로 활용하는 방식이 현장 적용에 보다 적절하다.

셋째, AI 채점의 신뢰도 검증 기준을 단순한 점수 일치율에서 불일치 원인 분석으로 확장할 필요가 있다. 같은 성취수준으로 분류되더라도 세부 점수와 판단 근거가 다를 수 있으며, 반대로 분할점수 경계에서는 작은 점수 차이가 다른 성취수준으로 나타날 수도 있다. 따라서 교사-AI 총점 일치율뿐 아니라 성취수준 일치, 평가요소별 판단 차이, OCR 오류, 루브릭 해석 차이 등을 함께 분석하는 표준적인 검증 절차가 필요하다.

넷째, AI 기반 학생평가를 활용할 경우 학생 개인정보와 평가정보에 대한 보호 체계를 함께 마련할 필요가 있다. 학교에서는 AI 평가 서비스 도입 전에 학생 정보의 수집·이용 범위, 비식별 처리 방식, 데이터의 저장·전송 및 파기 절차, 제3자 제공·위탁 여부 등을 확인하고, 필요한 경우 학생 및 보호자의 동의 절차를 적절히 운영해야 한다. 특히 AI 활용의 편의성이나 채점 성능뿐 아니라 학생의 답안과 평가 결과가 안전하게 처리되는지를 서비스 선정과 운영의 중요한 기준으로 삼을 필요가 있다.

다섯째, 단계별 비계 질문은 '질문을 많이 제공하는 방식'이 아니라 학생에게 필요한 사고 경로를 적절하게 지원하는 방식으로 활용해야 한다. 특히 모든 비계 질문을 점수화할 경우 학생과 교사의 부담이 다시 증가할 수 있으므로, 학습 과정에서 활용하는 무점수 비계 질문과 실제 성취 판단에 활용하는 핵심 평가 질문을 구분할 필요가 있다. 또한 비계의 수준과 수는 학생의 학습 수준과 교과의 사고 특성을 고려하여 조절되어야 한다.

여섯째, 과정중심평가를 내실화하려면 평가 횟수뿐 아니라 평가를 설계・협의・피드백할 수 있는 시간을 확보해야 한다. 평가를 많이 실시하는 것이 반드시 과정중심평가의 질을 높이는 것은 아니다. 학교 규모와 교과 담당 구조에 따라 정기시험과 수행평가의 양을 적정화하고, 확보된 시간을 문항과 루브릭 공동 검토, 학생 피드백, 재학습에 활용할 수 있도록 학교의 평가 운영 자율성을 확대할 필요가 있다.

일곱째, AI가 만들어 낸 새로운 평가 문제를 반영한 학생평가 지침의 정비도 필요하다. AI 채점을 위해 상세한 루브릭을 마련할수록 채점의 일관성은 높아질 수 있지만, 지나치게 세부적인 기준을 사전에 공개할 경우 학생에게 사실상 답안의 일부를 제공하는 문제가 발생할 수 있다. 학생에게 공개하는 평가기준과 교사의 채점 일관성을 위한 상세 채점기준을 어떻게 구분・운영할 것인지에 대해 교육청 차원의 명확한 지침과 협의가 필요하다.

마지막으로 미래형 학생평가에서 표준화하고 일반화해야 할 것은 특정 AI 프로그램이나 완성된 문항이 아니라 ‘좋은 평가를 설계하는 원리’와 ‘교사-AI가 협업하는 원칙’이어야 한다. 교사가 먼저 학생에게 무엇을 배우게 하고 무엇을 평가할 것인지를 결정하고, AI는 그 과정에서 교사의 판단을 확장하고 재검토하게 하는 도구로 활용되어야 한다. 이러한 관점이 유지될 때 AI는 평가의 본질을 흔드는 기술이 아니라 교사의 평가 전문성을 강화하고 학생의 성장을 보다 정교하게 지원하는 도구로 기능할 수 있을 것이다.

Ⅷ 참고 문헌

한국교육과정평가원(2022). 국가수준 학업성취도평가의 CBA 전면 도입과 AI 기반 학력진단

한국교육과정평가원(2023). 컴퓨터 기반 서·논술형 평가를 위한 자동채점 방안 설계

서울대학교 교육전문대학원 석사학위 논문 (2024). 생성형 인공지능 기반 피드백 제공 서술형 평가 도구 개발 및 교육과정 효과분석

최진영·김지수·김형성(2025). 논술형 평가 전문성 강화를 위한 AI 자동채점 기반 평가자 협의 모델 개발: 교사-AI 협업을 중심으로. 교육정보미디어연구, 31(4), 1297-1329.

표선고등학교(2023). 서·논술형 평가 채점 신뢰도 향상을 위한 평가 프로세스 모델 개발 - IB DP 학교 적용을 통한 일반화 방안 모색. 정책연구학교 운영 보고서.

한국교육과정평가원(2026). 교과 서·논술형 평가 자동채점을 위한 인공지능 모델 적용 방안 연구(Ⅱ). KICE 연구리포트(책임 송민호).

서울특별시교육청(2024). 중등학교 서·논술형 평가 지원을 위한 AI 기반 평가 지원 도구 개발 타당성 연구. (연구책임 하민수)

경기도교육연구원(2025). 하이러닝 AI 서·논술형 평가시스템 연구.

함은혜·김수연·임다미(2026). 단위학교 서·논술형 평가 역량 지원 방안과 정책 요구도 분석. 한국교원교육연구, 43(2).

덕원중학교(2025). AIDT 기반 개인 맞춤형 평가와 AI 코스웨어 활용 성찰중심의 과정중심평가를 통한 자기관리역량 신장 연구. 정책연구학교 운영 보고서.

한국교육과정평가원(2024). 교과 서·논술형 평가 자동채점을 위한 인공지능 모델 적용 방안 연구(Ⅰ). 연구보고 RRE 2024-9.

최진영 외(2026). AI와 교사 평가의 재구성. 커뮤니케이션북스.

에듀니티교육연구소(2026). AI 시대 서·논술형 평가 설계 바이블. 에듀니티.

화원중학교(2024). 탐구질문 중심의 과정중심평가-수업 운영을 통한 학생 미래역량 함양 방안. 정책연구학교 운영 보고서.

성재중학교(2025). 2022 개정 교육과정 기반 깊이있는 학습을 위한 학생평가 실행 연구. 정책연구학교 운영 보고서.

함은혜·박소영·이병윤·김기동·이대형(2024). ChatGPT를 활용한 서술형 문항 생성 프로토콜과 문항의 질 평가: 국어과 사례를 중심으로. 교육학연구, 62(8), 63-91.

성정원·신병철(2023). ChatGPT를 활용한 서·논술형 평가 자동 채점 가능성 탐색: 세계지리 서·논술형 평가를 중심으로. 한국지리학회지, 12(3).

동신중학교(2025). 디지털 기능을 활용한 과정중심평가 실현 방안. 정책연구학교 운영 보고서.

경기도교육청(2025). 경기교육 AI 서·논술형 평가시스템 이해자료.

부 록

1 실태 조사 문항

가. 학생 실태조사 문항

번호	조사 영역	문항	응답 형식
1	서·논술형 평가 인식	학생의 사고 과정을 평가하는 데 가장 적합한 평가 유형은 무엇이라고 생각합니까?	선택형
2	수업·평가와 삶의 연계	우리 학교의 수업과 평가는 학생의 실제 삶과 잘 연결되어 있다고 생각합니까?	5점 척도
3	AI 채점 인식	AI가 학생의 서·논술형 답안을 채점할 경우 가장 우려되는 점은 무엇입니까?	선택형
4	평가 피드백	평가가 끝난 후 교사로부터 제공받는 피드백은 자신의 학습 상태를 이해하는 데 충분하다고 생각합니까?	5점 척도
5	피드백 요구	평가 후 자신의 학습 수준과 부족한 부분을 알 수 있도록 지금보다 더 많은 피드백이 필요하다고 생각합니까?	5점 척도

나. 교사 실태조사 문항

번호	조사 영역	문항	응답 형식
1	서·논술형 평가 인식	학생의 사고 과정을 평가하는 데 가장 적합한 평가 유형은 무엇이라고 생각합니까?	선택형
2	수업·평가와 삶의 연계	우리 학교의 수업과 평가는 학생의 실제 삶과 잘 연결되어 있다고 생각합니까?	5점 척도
3	AI 채점 인식	AI가 학생의 서·논술형 답안을 채점할 경우 가장 우려되는 점은 무엇입니까?	선택형
4	서·논술형 평가 확대	서·논술형 평가를 확대할 경우 가장 우려되는 점은 무엇입니까?	선택형
5	교사 평가 역량	미래형 학생평가를 효과적으로 운영하기 위해 교사에게 가장 필요하다고 생각하는 역량이나 지원은 무엇입니까?	서술형

2 만족도 조사 문항

※ 응답척도: 5점 Likert 척도 ① 전혀 그렇지 않다 ② 그렇지 않다 ③ 보통이다 ④ 그렇다 ⑤ 매우 그렇다

가. 학생 만족도 조사 문항

번호	조사 영역	문항
1	서·논술형 평가 인식	서·논술형 평가는 학습 내용을 이해하고 나의 생각을 표현하는 데 도움이 되었다.
2	교실-삶 이음 평가	교과에서 배운 내용을 실제 생활이나 사회 문제와 연결하여 생각하는 평가는 의미가 있다고 생각한다.
3	평가문항 이해	서·논술형 문제를 풀 때 질문의 의도와 답안작성 조건을 확인하며 답을 작성하게 되었다.
4	단계별 비계 질문	단계별 질문은 한 번에 긴 글을 쓰는 부담을 줄이고 생각을 순서대로 정리하는 데 도움이 되었다.
5	논리적 표현	서·논술형 평가를 경험하면서 주장과 이유·근거를 구분하여 나의 생각을 표현하는 데 도움이 되었다.
6	평가 운영 방식	정기시험 횟수를 줄이고 수행평가의 반영 비율을 높인 현재의 평가 방식이 학생의 학습과 성취를 평가하는 데 적절하다고 생각한다.
7	AI 활용 신뢰	AI가 채점하더라도 교사가 AI의 채점 결과를 확인하고 최종 판단하는 것이 필요하다고 생각한다.

나. 교사 만족도 조사 문항

번호	조사 영역	문항
1	서·논술형 평가 인식	연구학교 운영을 통해 서·논술형 평가의 목적과 의미를 이전보다 명확하게 이해하게 되었다.
2	평가도구 개발 역량	성취기준을 분석하여 평가요소를 도출하고 이를 평가문항과 연결하는 역량이 향상되었다.
3	교실-삶 이음 문항	교과에서 배운 지식을 학생의 삶이나 사회 문제와 연결하는 평가문항을 개발하는 역량이 향상되었다.
4	단계별 비계 질문	단계별 질문은 학생의 사고과정을 드러내고 글쓰기 부담을 완화하는 데 도움이 된다고 생각한다.
5	평가요소 간 연계	연구학교 운영을 통해 성취기준·평가요소·문항·루브릭 간 연계성을 이전보다 중요하게 인식하게 되었다.
6	AI 활용 방향	AI는 교사의 채점을 대신하기보다 평가도구 개발과 채점 판단을 지원하는 도구로 활용하는 것이 적절하다고 생각한다.
7	AI 교차채점	AI와 교사의 채점 결과를 비교하는 과정은 루브릭과 평가도구의 문제점을 발견하고 채점의 질을 높이는 데 도움이 되었다.

번호	조사 영역	문항
8	평가 운영 개선	정기시험 횟수 조정과 공동 협의 운영은 수행평가를 보다 내실 있게 설계하고 운영하는 데 도움이 되었다.
9	평가 전문성	연구학교 운영과 AI 활용 경험은 교사의 학생평가 전문성을 향상하는 데 도움이 되었다.

3 이음 평가도구 개발 프로그램

❍ 이음(E-UM) AI 서·논술형 평가도구 설계 스튜디오



2022 개정 교육과정의 성취기준과 성취수준을 기반으로, 교과 지식을 학생의 실제 삶과 연결하는 서·논술형 평가도구 개발을 지원하는 AI 기반 프로그램이다. 성취기준 분석부터 평가요소 도출, 탐구질문 및 단계형 질문 설계, 루브릭 개발, 최종 검토까지 7단계의 설계 과정을 지원한다. AI의 생성 결과를 교사가 검토·수정·보완함으로써 교육과정에 근거한 평가도구를 개발할 수 있다.

❍ 이음(E-UM) 서·논술형 평가 지원 프롬프트 공유 웹페이지



별도의 프로그램 설치나 개발 과정 없이 생성형 AI를 활용하여 서·논술형 평가를 설계하고 채점할 수 있도록 지원하는 프롬프트 공유 웹페이지이다. '평가도구 설계 도우미'와 '답안 채점·피드백 도우미'를 제공하며, 교사는 프롬프트를 복사하여 사용하는 생성형 AI의 대화창에서 활용할 수 있다. 성취기준·성취수준·루브릭을 기반으로 AI와 교사가 대화하며 평가도구를 개발하고, 학생 답안을 분석하여 근거 중심의 채점과 맞춤형 피드백을 지원한다.

https://숏.한국/웅촌/이음_평가도구개발/	https://숏.한국/웅촌/이음_프롬프트/

UNGCHON MIDDLE SCHOOL

웅촌중학교

UNGCHON MIDDLE SCHOOL

울산광역시 울주군 웅촌면 새초천길 13
교장실 052) 225-0033 교무실 052) 225-0031
행정실 052) 225-4767 팩 스 052)225-7550